

Convergência

Quase certa

X

n

{\displaystyle X_{n}}

→

q.c.

X

{\displaystyle X_{n}\rightarrow X\ {\rm {q.c.}}}

 se

P
(
lim

n
→
∞

X

n

=
X
)
=
1

{\displaystyle P(\lim _{n\rightarrow \infty }X_{n}=X)=1}

Em probabilidade

X

n

{\displaystyle X_{n}}

→

P

X

{\displaystyle X_{n}\rightarrow X\ {\rm {P}}}

 se

lim

n
→
∞

P
(
|

X

n

−
X
|
>
ϵ
)
=
0

{\displaystyle \lim _{n\rightarrow \infty }P(|X_{n}-X|>\epsilon)=0}

 para todo

ϵ
>
0

{\displaystyle \epsilon >0}

Em distribuição

X

n

{\displaystyle X_{n}}

→

d

X

{\displaystyle X_{n}\rightarrow X\ {\rm {d}}}

 se

lim

n
→
∞

F

X

n

(
x
)
=

F

X

(
x
)

{\displaystyle \lim _{n\rightarrow \infty }F_{X_{n}}(x)=F_{X}(x)}

 em pontos de continuidade de

F

X

{\displaystyle F_{X}}

Borel-Cantelli I Se

∑

n
=
1

∞

P

(

A

n

)
<
∞
,

{\displaystyle \sum _{n=1}^{\infty }P(A_{n})<\infty ,}

 então

P
(
lim

sup

n
→
∞

A

n

)
=
0

{\displaystyle P(\limsup _{n\rightarrow \infty }A_{n})=0}

Borel-Cantelli II Se

(

A

n

)

{\displaystyle (A_{n})}

 são independentes e

∑

n
=
1

∞

P

(

A

n

)
=
∞
,

{\displaystyle \sum _{n=1}^{\infty }P(A_{n})=\infty ,}

 então

P
(
lim

sup

n
→
∞

A

n

)
=
1

{\displaystyle P(\limsup _{n\rightarrow \infty }A_{n})=1}

Limite superior

lim

sup

n
→
∞

A

n

=

⋂

n
=
1

∞

⋃

k
=
n

∞

A

k

=
{

A

n

{\rm {ocorre infinitas vezes}}

{\displaystyle \limsup _{n\rightarrow \infty }A_{n}=\bigcap _{n=1}^{\infty }\bigcup _{k=n}^{\infty }A_{k}=\{A_{n}{\rm {ocorre infinitas vezes}}\}}

Limite inferior

lim

inf

n
→
∞

A

n

=

⋃

n
=
1

∞

⋂

k
=
n

∞

A

k

=
{

A

n

{\rm {ocorre finitas vezes}}

{\displaystyle \liminf _{n\rightarrow \infty }A_{n}=\bigcup _{n=1}^{\infty }\bigcap _{k=n}^{\infty }A_{k}=\{A_{n}{\rm {ocorre finitas vezes}}\}}

Lei Fraca dos Grandes Números

(

X

n

)

{\displaystyle (X_{n})}

 i.i.d.,

E
[

X

1

]
=
μ
,

{\displaystyle E[X_{1}]=\mu ,}

Var
(

X

1

)
<
∞
⇒

X
¯

n

→

P

μ

{\rm {ou}}

S
¯

n

→

P

μ

{\displaystyle \mathrm {Var} (X_{1})<\infty \Rightarrow {\overline {X}}_{n}\rightarrow P\mu {\rm {ou}}{\overline {S}}_{n}\rightarrow P\mu }

Lei Forte dos Grandes Números

(

X

n

)

{\displaystyle (X_{n})}

 i.i.d.,

E
[
|

X

1

|
]
<
∞
,

{\displaystyle E[|X_{1}|]<\infty ,}

E
[

X

1

]
=
μ
⇒

X
¯

n

→

q.c.

μ

{\rm {ou}}

S
¯

n

→

q.c.

μ

{\displaystyle E[X_{1}]=\mu \Rightarrow {\overline {X}}_{n}\rightarrow q.c.\mu {\rm {ou}}{\overline {S}}_{n}\rightarrow q.c.\mu }

Desigualdade de Markov

X
≥
0
,
E
[
X
]
<
∞
⇒
P
(
X
≥
a
)
≤

E
[
X
]

a

{\displaystyle X\geq 0,E[X]<\infty \Rightarrow P(X\geq a)\leq {\frac {E[X]}{a}}}

 para

a
>
0

{\displaystyle a>0}

Desigualdade de Chebyshev

E
[
(
X
−
c

)

2

]
<
∞
⇒
P
(
(
X
−
c

)

2

≥

ε

2

)
≤

E
[
(
X
−
c

)

2

]

ε

2

{\displaystyle E[(X-c)^{2}]<\infty \Rightarrow P((X-c)^{2}\geq \varepsilon ^{2})\leq {\frac {E[(X-c)^{2}]}{\varepsilon ^{2}}}}

 onde

(
X
−
c

)

2

≥

ε

2

⇔
|
X
−
c
|
≥
ε
.

{\displaystyle (X-c)^{2}\geq \varepsilon ^{2}\Leftrightarrow |X-c|\geq \varepsilon .}

 Formas usuais:

P
(
|
X
−
μ
|
≥
ε
)
≤

σ

2

ε

2

{\displaystyle P(|X-\mu |\geq \varepsilon)\leq {\frac {\sigma ^{2}}{\varepsilon ^{2}}}}

 e

P
(
|
X
−
μ
|
≥
k
σ
)
≤

1

k

2

{\displaystyle P(|X-\mu |\geq k\sigma)\leq {\frac {1}{k^{2}}}}

Relações de convergência

X

n

{\displaystyle X_{n}}

→

q.c.

X
⇒

X

n

→

P

X
⇒

X

n

→

d

X

e

X

n

→

d

c
(
constante
)
⇒

X

n

→

P

c

{\displaystyle X_{n}\rightarrow q.c.X\Rightarrow X_{n}\rightarrow P X\Rightarrow X_{n}\rightarrow d X\ {\rm {e}}\ X_{n}\rightarrow d c\ {\rm {(constante)}}\Rightarrow X_{n}\rightarrow P c}

Método Delta Se

√
n
(

Y

n

−
μ
)

{\displaystyle {\sqrt {n}}(Y_{n}-\mu)}

→

d

N
(
0
,

σ

2

)

{\displaystyle {\sqrt {n}}(Y_{n}-\mu)\rightarrow d N(0,\sigma ^{2})}

 e

g

{\displaystyle g}

 é derivável em

μ
,

{\displaystyle \mu ,}

 então

√
n
(
g
(

Y

n

)
−
g
(
μ
)
)

{\displaystyle {\sqrt {n}}(g(Y_{n})-g(\mu))}

→

d

N
(
0
,

σ

2

(
g
′
(
μ
)

)

2

)

{\displaystyle {\sqrt {n}}(g(Y_{n})-g(\mu))\rightarrow d N(0,\sigma ^{2}(g'(\mu))^{2})}

Teorema Central do Limite

Forma assintótica

(

X

n

)

{\displaystyle (X_{n})}

 i.i.d.,

E
[

X

1

]
=
μ
,

{\displaystyle E[X_{1}]=\mu ,}

Var
(

X

1

)
=

σ

2

<
∞
⇒

S
¯

n

−
n
μ

σ

√
n

→

d

N
(
0
,
1
)

{\rm {onde}}

S

n

=

∑

i
=
1

n

X

i

{\displaystyle \mathrm {Var} (X_{1})=\sigma ^{2}<\infty \Rightarrow {\frac {\overline {S}}{n}}-{\frac {\mu }{\sigma {\sqrt {n}}}}\rightarrow d N(0,1){\rm {onde}}S_{n}=\sum _{i=1}^{n}X_{i}}

Aprox. para somas Se

Y
=

X

1

+
⋯
+

X

n

{\rm {com}}

X

i

{\rm {i.i.d.}},

{\displaystyle Y=X_{1}+\cdots +X_{n}{\rm {com}}X_{i}{\rm {i.i.d.}},}

 então

Y
≈
N
(
n
μ
,
n

σ

2

)

{\rm {para}}

n

{\rm {grande}}

{\displaystyle Y\approx N(n\mu ,n\sigma ^{2}){\rm {para}}n{\rm {grande}}}

Aprox. para médias

X
¯

n

=
1

n

∑

i
=
1

n

X

i

≈
N
(
μ
,

σ

2

n

)

{\rm {para}}

n

{\rm {grande}}

{\displaystyle {\overline {X}}_{n}={\frac {1}{n}}\sum _{i=1}^{n}X_{i}\approx N\left(\mu ,{\frac {\sigma ^{2}}{n}}\right){\rm {para}}n{\rm {grande}}}

Padronização

√
n
(
X
¯

n

−
μ
)

σ

→

d

N
(
0
,
1
)
,

√
n
(
X
¯

n

−
μ
)

→

d

N
(
0
,

σ

2

)

{\displaystyle {\frac {\sqrt {n}({\overline {X}}_{n}-\mu)}{\sigma }}\rightarrow d N(0,1),{\sqrt {n}}({\overline {X}}_{n}-\mu)\rightarrow d N(0,\sigma ^{2})}

Teorema de Slutsky

Se g : R →<!-- → --> R {\displaystyle g:\mathbb {R} \rightarrow \mathbb {R} } é continua:	
(a) X n {\displaystyle X_{n}} →<!-- → --> q.c. X ⇒<!-- ⇒ --> g (X n) →<!-- → --> q.c. g (X) {\displaystyle X_{n}\rightarrow q.c.X\Rightarrow g(X_{n})\rightarrow q.c.g(X)} 	Se X n →<!-- → --> d X {\rm {e}} Y n →<!-- → --> P c {\displaystyle X_{n}\rightarrow d X{\rm {e}}Y_{n}\rightarrow P c} :
(b) X n →<!-- → --> P X ⇒<!-- ⇒ --> g (X n) →<!-- → --> P g (X) {\displaystyle X_{n}\rightarrow P X\Rightarrow g(X_{n})\rightarrow P g(X)} 	(a) X n + Y n →<!-- → --> d X + c {\displaystyle X_{n}+Y_{n}\rightarrow d X+c}
(c) X n →<!-- → --> d X ⇒<!-- ⇒ --> g (X n) →<!-- → --> d g (X) {\displaystyle X_{n}\rightarrow d X\Rightarrow g(X_{n})\rightarrow d g(X)} 	(b) X n −<!-- − --> Y n →<!-- → --> d X −<!-- − --> c {\displaystyle X_{n}-Y_{n}\rightarrow d X-c}
	(c) Y n X n →<!-- → --> d c X {\displaystyle {\frac {Y_{n}}{X_{n}}}\rightarrow d cX}
	(d) X n Y n →<!-- → --> d c c {\rm {se}} c ≠<!-- ≠ --> 0 {\displaystyle {\frac {X_{n}}{Y_{n}}}\rightarrow d {\frac {c}{c}}{\rm {se}}c\neq 0}

Estimadores de Bayes

Na abordagem Bayesiana, os estimadores são calculados considerando a distribuição a priori dos parâmetros e a função de verossimilhança dos dados.

Cálculo da Distribuição a Posteriori

Teorema de Bayes

f
(
θ
|

x
)
=

f
(
θ
)
f
(

x
|
θ
)

∫

Θ

f
(
θ
)
f
(

x
|
θ
)
d
θ

∝
f
(
θ
)
⋅
f
(

x
|
θ
)

{\displaystyle f(\theta |x)={\frac {f(\theta)f(\mathbf {\theta })}{\int _{\Theta }f(\theta)f(\mathbf {\theta })d\theta }}\propto f(\theta)\cdot f(\mathbf {\theta })}

Passos principais (1) Identificar verossimilhança do modelo dos dados, (2) Escolher priori apropriada, (3) Multiplicar priori × verossimilhança, (4) Normalizar (ou reconhecer família de distribuições)

Prioris conjugadas Facilitam o cálculo - produzem posteriores na mesma família da priori. Basta atualizar hiperparâmetros com dados observados

Exemplo rápido

X
|
θ
∼
Bin
(
n
,
θ
)
,

θ
∼
Beta
(
a
,
b
)
⇒
θ
|
X
=
x
∼
Beta
(
a
+
x
,
b
+
n
−
x
)

{\displaystyle X|\theta \sim \mathrm {Bin} (n,\theta),\theta \sim \mathrm {Beta} (a,b)\Rightarrow \theta |X=x\sim \mathrm {Beta} (a+x,b+n-x)}

Estimação Pontual e Funções de Perda

Risco a posteriori

r

x

(
d
)
=

∫

Θ

L
(
d
,
θ
)
d
P
(
θ
|

x
)

{\displaystyle r_{\mathbf {x} }(d)=\int _{\Theta }L(d,\theta)\,dP(\theta |x)}

 (minimizar perda esperada a posteriori)

Perda quadrática

L
(
d
,
θ
)
=
(
d
−
θ
)

2

⇒

δ

∗

(

X
)
=
E
[
θ
|

X
]

{\displaystyle L(d,\theta)=(d-\theta)^{2}\Rightarrow \delta ^{*}(\mathbf {X})=E[\theta |X]}

 (média a posteriori)

Perda absoluta

L
(
d
,
θ
)
=
|
d
−
θ
|
⇒

δ

∗

(

X
)
=
Med
(
θ
|

X
)

{\displaystyle L(d,\theta)=|d-\theta |\Rightarrow \delta ^{*}(\mathbf {X})=\mathrm {Med} (\theta |X)}

 (mediana a posteriori)

Risco de Bayes Sob perda quadrática:

ρ

∗

(
P
)
=
E
[
Var
(
θ
|

X
)
]

{\displaystyle \rho ^{*}(P)=E[\mathrm {Var} (\theta |X)]}

 (variância a posteriori esperada)

Exemplo Poisson Com priori Gamma:

δ

∗

(

X
)
=

b

b
+
n

⋅

a

b

+

n

b
+
n

⋅
X
¯

{\displaystyle \delta ^{*}(\mathbf {X})={\frac {b}{b+n}}\cdot {\frac {a}{b}}+{\frac {n}{b+n}}\cdot {\bar {X}}}

 (média ponderada: priori + amostra)

Famílias Conjugadas

Definição intuitiva Família de prioris

C

{\displaystyle C}

 é conjugada à verossimilhança

P

{\rm {se}}

P

{\rm {priori}}

{\displaystyle C{\rm {é}}conjugada\ {\rm {a}}\ {\rm {verossimilhança}}\ {\rm {se}}\ {\rm {P}}{\rm {se}}\ {\rm {priori}}}

Vantagens (1) Tratabilidade analítica - posteriori conhecida, (2) Computação simples - apenas atualizar hiperparâmetros, (3) Interpretação clara de como dados mudam crenças

Insight chave Conjugação é conveniência matemática, não requisito. Prioris não-conjugadas requerem métodos numéricos (MCMC). A priori conjugada “fala a mesma linguagem matemática” da verossimilhança

Estimação por Máxima Verossimilhança

Propriedades

Invariância Se

θ
^

{\displaystyle {\hat {\theta }}}

 é um estimador de

θ
,

{\displaystyle \theta ,}

 então

g
(
θ
^
)

{\displaystyle g({\hat {\theta }})}

 é um estimador de

g
(
θ
)

{\displaystyle g(\theta)}

 para qualquer função

g
.

{\displaystyle g.}

Consistência Se

θ
^

n

{\displaystyle {\hat {\theta }}_{n}}

 é uma sequência de estimadores de

θ
,

{\displaystyle \theta ,}

 então

θ
^

n

→

P

θ
.

{\displaystyle {\hat {\theta }}_{n}\rightarrow P\theta .}

Cálculo da EMV

Método Maximizar

L
(
θ
|

x
)
=
f
(

x
|
θ
)

{\displaystyle L(\theta |x)=f(x|\theta)}

≡

i.n.d..

∏

i
=
1

n

f
(

x

i

|
θ
)

{\rm {ou}}

ℓ
(
θ
|

x
)
=

∑

i
=
1

n

log
⁡
f
(

x

i

|
θ
)

{\displaystyle \ell (\theta |x)=\sum _{i=1}^{n}\log f(x_{i}|\theta)}

Condição I

d
ℓ
(
θ
|

x
)

d
θ

=
0

{\rm {função}}

{\rm {score}}

{\displaystyle {\frac {d\ell (\mathbf {x})}{d\theta }}=0{\rm {função}}{\rm {score}}}

Condição II

d

2

ℓ
(
θ
)

d
θ

2

<
0

{\rm {segunda}}

{\rm {derivada}}

{\rm {negativa}}

{\rm {no}}

{\rm {ponto}}

{\rm {de}}

{\rm {máximo}}.

{\displaystyle {\frac {d^{2}\ell (\theta)}{d\theta ^{2}}}<0{\rm {segunda}}{\rm {derivada}}{\rm {negativa}}{\rm {no}}{\rm {ponto}}{\rm {de}}{\rm {máximo}}.}

Notação

f
(

x
|
θ
)
=

V

x

(
θ
)

{\rm {e}}

log
⁡
f
(

x
|
θ
)
=
λ
(
θ
,

x
)

{\displaystyle f(\mathbf {x} |\theta)=V_{\mathbf {x} }(\theta){\rm {e}}\log f(\mathbf {x} |\theta)=\lambda (\theta ,\mathbf {x})}

Condições de regularidade

1 Podemos trocar a ordem de derivada e integração (portanto é diferenciabilidade é condição necessária).

2 O suporte da verossimilhança não depende do parâmetro

θ
.

{\displaystyle \theta .}

Propriedades Assintóticas

Normalidade

√
n
(
θ
^

n

−
θ
)

→

d

N
(
0
,

I

−
1

(
θ
)
)

{\displaystyle {\sqrt {n}}({\hat {\theta }}_{n}-\theta)\rightarrow d N(0,I^{-1}(\theta))}

Eficiência EMV atinge a cota de Cramér-Rao assintoticamente.

Estatísticas Suficientes

Suficiência frequentista

T
(

X
)

{\displaystyle T(\mathbf {X})}

 é suficiente para

θ

{\displaystyle \theta }

 se

f
(

x
|
T
(

x
)
,
θ
)
=
f
(

x
|
T
(

x
)
)

{\displaystyle f(\mathbf {x} |T(\mathbf {x}),\theta)=f(\mathbf {x} |T(\mathbf {x}))}

Suficiência Bayesiana

T
(

X
)

{\displaystyle T(\mathbf {X})}

 é suficiente para

θ

{\displaystyle \theta }

 se

f
(
θ
|
T
(

x
)
)
=
f
(
θ
|

x
)

{\displaystyle f(\theta |T(\mathbf {x})=f(\theta |x)}

Critério da fatoração de Neyman-Pearson

T
(

X
)

{\displaystyle T(\mathbf {X})}

 é suficiente ⇔

f
(

x
|
θ
)
=
g
(
T
(

x
)
,
θ
)
h
(

x
)

{\displaystyle f(\mathbf {x} |\theta)=g(T(\mathbf {x}),\theta)h(\mathbf {x})}

Propriedades

Minimal

T

{\displaystyle T}

 é minimal suficiente se é função de qualquer outra estatística suficiente

Estimadores não viesados de variância uniformemente mínima

Teorema de Lehmann-Scheffé

Enunciado Se

T
(

X
)

{\displaystyle T(\mathbf {X})}

 é completa e suficiente, então qualquer estimador não viesado baseado em

T
(

X
)

{\displaystyle T(\mathbf {X})}

 é ENNVUM e é único.

Estatística Completa

T
(

X
)

{\displaystyle T(\mathbf {X})}

 é completa se

E
[
g
(
T
(

X
)
)
]
=
0

{\rm {para}}

{\rm {todo}}

θ
⇒
g
(
T
(

X
)
)
=
0

{\rm {q.c.}}

{\displaystyle E[g(T(\mathbf {X}))]=0{\rm {para}}{\rm {todo}}\theta \Rightarrow g(T(\mathbf {X}))=0{\rm {q.c.}}}

Teorema de Rao-Blackwell

Enunciado Se

δ
(

X
)

{\displaystyle \delta (\mathbf {X})}

 é não viesado e

T
(

x
)

{\displaystyle T(\mathbf {x})}

 é suficiente, então

δ

∗

(

X
)
=
E
[
δ
(

X
)
|
T
(

X
)
]
=
g
(
T
(

X
)
)

{\rm {tem}}

{\rm {variância}}

{\rm {menor}}

{\rm {ou}}

{\rm {igual}}

{\displaystyle \delta ^{*}(\mathbf {X})=E[\delta (\mathbf {X})|T(\mathbf {X})]=g(T(\mathbf {X})){\rm {tem}}{\rm {variância}}{\rm {menor}}{\rm {ou}}{\rm {igual}}}

Resultado

Var
(

δ

∗

(

X
)
)
≤
Var
(
δ
(

X
)
)

{\rm {com}}

{\rm {igualdade}}

{\rm {se}}

{\rm {e}}

{\rm {somente}}

{\rm {se}}

δ
(

X
)

{\rm {é}}

{\rm {função}}

{\rm {de}}

T
(

X
)

{\displaystyle \mathrm {Var} (\delta ^{*}(\mathbf {X}))\leq \mathrm {Var} (\delta (\mathbf {X})){\rm {com}}{\rm {igualdade}}{\rm {se}}{\rm {e}}{\rm {somente}}{\rm {se}}\delta (\mathbf {X}){\rm {é}}{\rm {função}}{\rm {de}}T(\mathbf {X})}

Rao-Blackwellização

Processo Melhorar estimador não viesado condicionando em estatística suficiente

Fórmula

θ
^

R
B

=
E
[
θ
|
T
(

X
)
]

{\rm {onde}}

T
(

X
)

{\rm {é}}

{\rm {suficiente}}

{\rm {para}}

θ

{\displaystyle {\hat {\theta }}^{RB}=E[\theta |T(\mathbf {X})]{\rm {onde}}T(\mathbf {X}){\rm {é}}{\rm {suficiente}}{\rm {para}}\theta }

Desigualdade de Cramér-Rao

Limite inferior de Cramér-Rao

Var
(
θ
^
)
≥

[

g
′
(
θ
)

]

2

I
(
θ
)

{\displaystyle \mathrm {Var} ({\hat {\theta }})\geq {\frac {[g'(\theta)]^{2}}{I(\theta)}}}

 onde

I
(
θ
)

{\displaystyle I(\theta)}

 é a informação de Fisher.

Informação de Fisher

I
(
θ
)
=
E
[
(

∂

g
′
(
θ
)

∂
θ

log
⁡
f
(

X
;
θ
)

)

2

]
=
−
E
[
(
(

∂

2

log
⁡
f
(

X
;
θ
)

∂
θ

2

)
)
]

{\displaystyle I(\theta)=E\left[\left({\frac {\partial g'(\theta)}{\partial \theta }}\log {\mathbf {X} ;\theta })^{2}\right]=-E\left[\left({\frac {\partial ^{2}}{\partial \theta ^{2}}}\log f(\mathbf {X} ;\theta)\right)\right]}

Informação de Fisher para v.a. i.i.d

I
(
θ
)
=
−
n
E
[
(

∂

2

log
⁡
f
(

X
;
θ
)

∂
θ

2

)
]

{\displaystyle I(\theta)=-nE\left[\left({\frac {\partial ^{2}}{\partial \theta ^{2}}}\log f(\mathbf {X} ;\theta)\right)\right]}

Relação com ENNVUM se a variância do estimador coincide com o limite inferior de Cramér-Rao, o estimador é ENNVUM.

Intervalos de confiança

Estimador Intervalar

[
L
(

X
,
U
(

X
)
)
]

{\displaystyle [L(\mathbf {X} ,U(\mathbf {X}))]}

 onde

L

{\displaystyle L}

 e

U

{\displaystyle U}

 são estatísticas e v.a.

Nível de confiança

P
(
L
(

X
)
≤
θ
≤
U
(

X
)
)
)
=
1
−
α
=
γ

{\displaystyle P(L(\mathbf {X})\leq \theta \leq U(\mathbf {X}))=1-\alpha =\gamma }

Quantidade Pivotal

Q
(

X
)

{\displaystyle Q(\mathbf {X})}

 é uma quantidade pivotal se

Q
(

X
)

{\displaystyle Q(\mathbf {X})}

 tem distribuição não dependente de

θ
.

{\displaystyle \theta .}

QP média amostral

X

i

∼
N
(
μ
,

σ

2

)

{\rm {então}}

X
¯

n

−
μ

σ

√

σ

2

n

∼

Lista de famílias Conjugadas

Bernoulli/Binomial Priori: $p \sim \text{Beta}(\alpha, \beta) \Rightarrow$ Posteriori: $p|\mathbf{x} \sim \text{Beta} \left(\alpha + \sum x_i, \beta + n - \sum x_i \right)$

Poisson Priori: $\lambda \sim \text{Gama}(\alpha, \beta) \Rightarrow$ Posteriori: $\lambda|\mathbf{x} \sim \text{Gama} \left(\alpha + \sum x_i, \beta + n \right)$

Geométrica Priori: $p \sim \text{Beta}(\alpha, \beta) \Rightarrow$ Posteriori: $p|\mathbf{x} \sim \text{Beta} \left(\alpha + n, \beta + \sum x_i \right)$

Normal (média desconhecida) Priori: $\mu \sim \text{Normal}(\mu_0, \sigma_0^2) \Rightarrow$ Posteriori: $\mu|\mathbf{x} \sim \text{Normal} \left(\frac{\sigma^2 \mu_0 + \sigma_0^2 n \bar{x}}{\sigma^2 + n \sigma_0^2}, \frac{\sigma^2 \cdot \sigma_0^2}{\sigma^2 + n \sigma_0^2} \right)$

Normal (variância desconhecida) Priori: $\sigma^2 \sim \text{Gama-Inversa}(\alpha, \beta) \Rightarrow$ Posteriori: $\sigma^2|\mathbf{x} \sim \text{Gama-Inversa} \left(\alpha + \frac{n}{2}, \beta + \frac{1}{2} \sum (x_i - \mu)^2 \right)$

Normal Multivariada Priori: $\Sigma \sim \text{Wishart}(\nu, \Psi) \Rightarrow$ Posteriori: $\Sigma|\mathbf{x} \sim \text{Wishart} \left(n + \nu, \Psi + \sum (\mathbf{x}_i - \mu)(\mathbf{x}_i - \mu)^T \right)$

Exponencial Priori: $\lambda \sim \text{Gama}(\alpha, \beta) \Rightarrow$ Posteriori: $\lambda|\mathbf{x} \sim \text{Gama} \left(\alpha + n, \beta + \sum x_i \right)$

Gama Priori: $\beta \sim \text{Gama}(a_0, b_0) \Rightarrow$ Posteriori: $\beta|\mathbf{x} \sim \text{Gama} \left(a_0 + n \alpha, b_0 + \sum x_i \right)$

Teste de hipóteses