

Formulário – Estatística Não-Paramétrica (Aulas 1–12)

Ferramentas

Markov / Chebyshev $\mathbb{P}(|T - \theta| \geq t) \leq \mathbb{E}|T - \theta|^r / t^r, r > 0$. Com $r = 2$ e $\mathbb{E}T = \theta$: $\mathbb{P}(|T - \theta| \geq t) \leq \mathbb{V}(T) / t^2$.

Hoeffding Y_i indep., $Y_i \in [a, b]$:
 $\mathbb{P}(|\bar{Y} - \mathbb{E}\bar{Y}| \geq \varepsilon) \leq 2 \exp(-2n\varepsilon^2 / (b - a)^2)$. Para sinais $\sigma_i a_i \in [-1, 1]$: $2e^{-n\varepsilon^2/2}$.

Borel-Cantelli I $\sum_n \mathbb{P}(A_n) < \infty \Rightarrow \mathbb{P}(A_n \text{ i.v.}) = 0$. **Uso:** se $\sum_n \mathbb{P}(|T_n - \theta| > \varepsilon) < \infty$ para todo $\varepsilon > 0$, então $T_n \xrightarrow{q.c.} \theta$. Toda cota exponencial em n vira convergência q.c.

Esperança via cauda $Z \geq 0 \Rightarrow \mathbb{E}Z = \int_0^\infty \mathbb{P}(Z \geq t) dt$.

LGN forte / TCL $\mathbb{E}|X_1| < \infty \Rightarrow \bar{X} \xrightarrow{q.c.} \mu$;
 $\sigma^2 < \infty \Rightarrow \sqrt{n}(\bar{X} - \mu) \xrightarrow{d} N(0, \sigma^2)$.

Slutsky $X_n \xrightarrow{d} X, Y_n \xrightarrow{P} c \Rightarrow X_n + Y_n \xrightarrow{d} X + c, Y_n X_n \xrightarrow{d} cX, X_n / Y_n \xrightarrow{d} X / c (c \neq 0)$.

Método delta $\sqrt{n}(Y_n - \mu) \xrightarrow{d} N(0, \Sigma), g$ diferenciável em μ
 $\Rightarrow \sqrt{n}(g(Y_n) - g(\mu)) \xrightarrow{d} N(0, \nabla g^T \Sigma \nabla g)$. Ex.: $\sqrt{\hat{F}_n(x)}$: variância assintótica $\frac{F(1-F)}{4F} = \frac{1-F(x)}{4}$.

Decomposição do risco $\text{MSE}(\hat{\theta}) = (\mathbb{E}\hat{\theta} - \theta)^2 + \mathbb{V}(\hat{\theta})$.

Cauchy-Schwarz $(\sum a_i b_i)^2 \leq \sum a_i^2 \sum b_i^2$; $\sum \ell_i^2 \leq \max_i |\ell_i| \sum_i |\ell_i|$.

Movimentos para integrais (viés/variância)

- Escrever $\mathbb{E}$ como integral:
 $\mathbb{E}[h^{-1}K((X - x)/h)] = \int h^{-1}K((y - x)/h)f(y) dy$.
- Mudança de variáveis $u = (y - x)/h, dy = h du$: $= \int K(u)f(x + uh) du$.
- Centrar com $\int K = 1$:
 $\int K(u)f(x + uh)du - f(x) = \int K(u)[f(x + uh) - f(x)]du$.
- Módulo para dentro: $|\int g| \leq \int |g|$; cotar o integrando com a suavidade.
- Fubini (integrando ≥ 0 ou integrável) para fatorar em kernels-produto.
- $\mathbb{V}(Z) \leq \mathbb{E}Z^2$; $\mathbb{V}(\bar{Z}) = \mathbb{V}(Z_1)/n$ para i.i.d.

Banda ótima (forma geral)

$g(h) = Ah^{2\beta} + \frac{B}{nh^{\frac{2\beta}{d}}}$ é convexa e minimizada em $h^* = \left(\frac{dB}{2\beta A n}\right)^{\frac{1}{2\beta+d}}$,

com $g(h^*) \asymp n^{-\frac{2\beta}{2\beta+d}}$.

Caso $\beta = d = 1$ (Aula 1, Lema 4): $g = L^2 h^2 + C/(nh)$,
 $h_C = (C/(2L^2 n))^{1/3}, g(h_C) = 3 \cdot 2^{-2/3} (LC)^{2/3} n^{-2/3}$.

Equilíbrio rápido: igualar $h^{2\beta} = 1/(nh^d) \Rightarrow h \asymp n^{-1/(2\beta+d)}$.

Distribuição empírica (Aula 2)

Definição $\hat{F}_n(x) = n^{-1} \sum_i \mathbb{I}(X_i \leq x)$; $n\hat{F}_n(x) \sim \text{Bin}(n, F(x))$.

Momentos $\mathbb{E}\hat{F}_n(x) = F(x), \mathbb{V}\hat{F}_n(x) = \frac{F(x)(1-F(x))}{n} \leq \frac{1}{4n}$;
 $\text{Cov}(\hat{F}_n(x), \hat{F}_n(y)) = \frac{F(x \wedge y) - F(x)F(y)}{n}$.

Pontual $\hat{F}_n(x) \xrightarrow{q.c.} F(x)$ e $\hat{F}_n(x^-) \xrightarrow{q.c.} F(x^-)$ (LGN).

Erro máximo $D_n = \sup_x |\hat{F}_n(x) - F(x)|$ (distância de Kolmogorov-Smirnov).

Discretização $x_j = \inf\{x : F(x) \geq j/k\}, x_0 = -\infty, x_k = \infty$:
 $D_n \leq \Delta_{n,k} + k^{-1}$, com $\Delta_{n,k}$ o máximo dos erros em x_j e x_j^- ($2(k+1)$ pontos).

Glivenko-Cantelli $D_n \xrightarrow{q.c.} 0$.

Velocidade $\mathbb{P}(D_n \geq \varepsilon) \leq \frac{16}{\varepsilon} e^{-n\varepsilon^2/2}, \varepsilon \in (0, 1] \Rightarrow D_n \leq 2\sqrt{n^{-1} \log n}$ q.c. para n grande.

DKW (Massart) $\mathbb{P}(D_n \geq \varepsilon) \leq 2e^{-2n\varepsilon^2}$ (constante 2 ótima).
 $\mathbb{E}D_n \leq \sqrt{\pi/(2n)}$.

Banda de confiança $\varepsilon_n = \sqrt{\log(2/\alpha)/(2n)}$:
 $\mathbb{P}(\hat{F}_n - \varepsilon_n \leq F \leq \hat{F}_n + \varepsilon_n \forall x) \geq 1 - \alpha$ (truncar em $[0, 1]$).

Classe GC $\mathcal{G}$ é GC para P se $\|P_n - P\|_{\mathcal{G}} = \sup_{g \in \mathcal{G}} |P_n g - P g| \xrightarrow{q.c.} 0$;
 $P_n g = n^{-1} \sum g(X_i)$.

Moldes de consistência

Funcional Lipschitz

$|T(G_1) - T(G_2)| \leq L\|G_1 - G_2\|_\infty \Rightarrow |T(\hat{F}_n) - T(F)| \leq LD_n \xrightarrow{q.c.} 0$,
com taxa $O(\sqrt{\log n/n})$ q.c.

Exemplos $T(F) = \int x dF$ com $|X| \leq M$:

$\int x dF = \int_0^M (1 - F) - \int_{-M}^0 F$, logo $L = 2M$. $T(F) = \int_0^M F^2$:

$|\mathcal{G}_1^2 - \mathcal{G}_2^2| = |G_1 + G_2||G_1 - G_2| \leq 2|G_1 - G_2| \Rightarrow L = 2M$.

Inversão do quantil Se $f \geq C_1$ entre x e y : $|F(x) - F(y)| \geq C_1|x - y|$.
Mediana amostral $(\hat{F}_n(\hat{m}^-) \leq \frac{1}{2} \leq \hat{F}_n(\hat{m}))$: $|\hat{F}_n(\hat{m}) - \frac{1}{2}| \leq n^{-1}$ (sem empates) e
 $C_1|\hat{m}_n - m| \leq |F(\hat{m}) - \hat{F}_n(\hat{m})| + |\hat{F}_n(\hat{m}) - F(m)| \leq D_n + n^{-1}$.

Dimensão VC (Aula 3)

Medida empírica $P_n(A) = n^{-1} \sum \mathbb{I}(X_i \in A)$; $\mathcal{C}$ é GC se

$\|P_n - P\|_{\mathcal{C}} \xrightarrow{q.c.} 0$. Contraexemplo: todos os borelianos com P contínua ($\mathcal{C} = \{X_1..X_n\}$).

Traço $\mathcal{C}_A = \{C \cap A : C \in \mathcal{C}\}$; $\mathcal{C}$ fragmenta A se $\mathcal{C}_A = 2^A$.

Coef. de fragmentação $s(\mathcal{C}, n) = \max_{|A|=n} |\mathcal{C}_A| \leq 2^n$.

Dimensão VC $\text{VC}(\mathcal{C}) = \sup\{n : s(\mathcal{C}, n) = 2^n\}$. Para $\text{VC} = d$: (i) exibir *um* conjunto de d pontos fragmentado; (ii) mostrar que *nenhum* conjunto de $d + 1$ pontos é fragmentado.

Sauer-Shelah $\text{VC} = d < \infty \Rightarrow s(\mathcal{C}, n) \leq \sum_{i=0}^d \binom{n}{i} \leq (n + 1)^d$.

Desig. de VC $\mathbb{P}(\|P_n - P\|_{\mathcal{C}} > \varepsilon) \leq 8s(\mathcal{C}, n)e^{-n\varepsilon^2/32}$.

Prova (cadeia) Simetrização ($n\varepsilon^2 \geq 2$): $\leq 2\mathbb{P}(\|P_n - P'_n\| > \frac{\varepsilon}{2}) \rightarrow$ sinais:
 $\leq 4\mathbb{P}(\sup |\frac{1}{n} \sum \sigma_i \mathbb{I}(X_i \in C)| > \frac{\varepsilon}{4}) \rightarrow$ contagem + Hoeffding:
 $\leq 8s(\mathcal{C}, n)e^{-n\varepsilon^2/32}$.

Corolário Classe $\text{VC} \Rightarrow \text{GC}$ universal (polinomial $\times$ exponencial é somável; Borel-Cantelli). Semirretas ($\text{VC} = 1$) $\Rightarrow$ Glivenko-Cantelli.

Radon $d + 2$ pontos em $\mathbb{R}^d$ admitem partição I, J com $\text{conv}(x_I) \cap \text{conv}(x_J) \neq \emptyset$ (cota superior para conjuntos convexos/semiespaços).

Operações $\{A \cup B\}$ ou $\{A \cap B\}$ com $A \in \mathcal{C}_1, B \in \mathcal{C}_2$:
 $s \leq s(\mathcal{C}_1, n) s(\mathcal{C}_2, n)$; complementos preservam VC ;
 $\mathcal{C} \subseteq \mathcal{C}' \Rightarrow \text{VC}(\mathcal{C}) \leq \text{VC}(\mathcal{C}')$.

Classe	VC
Semirretas $(-\infty, x]$ em $\mathbb{R}$	1
Intervalos $[a, b]$ em $\mathbb{R}$	2
Retângulos (lados paralelos) em $\mathbb{R}^2$	4
Semiespaços $\{\langle w, x \rangle \geq b\}$ em $\mathbb{R}^d$	$d + 1$
Discos em $\mathbb{R}^2$	3

Técnica em $\mathbb{R}$: ordene $x_1 < \dots < x_k$ e liste os padrões possíveis do traço; ache um rótulo impossível (ex.: incluir x_2, x_4 e excluir x_1, x_3).

Funcionais estatísticos (Aula 4)

Funcional / plug-in $T : \mathcal{D} \rightarrow \mathbb{R}$; plug-in $T(\hat{F}_n)$.

Linear $T(F) = \int g dF \Rightarrow T(\hat{F}_n) = n^{-1} \sum g(X_i)$, não-viesado,

$\mathbb{V} = \mathbb{V}[g(X_1)]/n, \sqrt{n}(T(\hat{F}_n) - T(F)) \xrightarrow{d} N(0, \mathbb{V}g(X_1))$.

Composição $T = h(\int g_1 dF, \dots, \int g_k dF)$, h contínua
 $\Rightarrow T(\hat{F}_n) \xrightarrow{q.c.} T(F)$. Ex.: variância, $h(a, b) = b - a^2$. Quantis *não* são composições.

Plug-in da variância $\hat{\sigma}^2 = n^{-1} \sum (X_i - \bar{X})^2, \mathbb{E}\hat{\sigma}^2 = \frac{n-1}{n} \sigma^2$.

Contaminação $F_{\varepsilon, x} = (1 - \varepsilon)F + \varepsilon\delta_x$.

Função de influência $\text{IF}(x) = \lim_{\varepsilon \downarrow 0} \frac{T(F_{\varepsilon, x}) - T(F)}{\varepsilon} = \frac{d}{d\varepsilon} T(F_{\varepsilon, x})|_{\varepsilon=0}$.
Sempre $\int \text{IF} dF = 0$ (checagem!).

$T(F)$	$\text{IF}(x)$
$\int g dF$	$g(x) - T(F)$
$\frac{\mu}{F(b) - F(a)}$	$\frac{x - \mu}{\mathbb{I}(a < x \leq b) - T(F)}$
σ^2	$\frac{(x - \mu)^2 - \sigma^2}{p - \mathbb{I}(x \leq \xi_p)}$
ξ_p (quantil)	$\frac{f(\xi_p)}{\text{sinal}(x - m)}$
mediana	$\frac{2f(m)}{}$

Cálculo de IF

Regra da cadeia $T = h(\theta_1, \dots, \theta_k), \theta_j = \int g_j dF$:
 $\text{IF}(x) = \sum_j \partial_j h(\theta) (g_j(x) - \theta_j)$.

Produto/quociente/potência $\text{IF}_{T_1 T_2} = T_2 \text{IF}_1 + T_1 \text{IF}_2$;
 $\text{IF}_{T_1/T_2} = \frac{\text{IF}_1 - (T_1/T_2)\text{IF}_2}{T_2}$; $\text{IF}_{T_1^a} = aT_1^{a-1} \text{IF}_1$.

Momento centrado $\mu_k(F) = \int (y - \mu(F))^k dF$: derivar a integral *e* o centro:
 $\text{IF}_{\mu_k}(x) = (x - \mu)^k - \mu_k - k\mu_{k-1}(x - \mu)$. ($k = 2$: $\mu_1 = 0$; $k = 3$: $-3\sigma^2(x - \mu)$.)

Assimetria $T = \mu_3/\sigma^3$:

$\text{IF} = \frac{(x - \mu)^3 - \mu_3 - 3\sigma^2(x - \mu)}{\sigma^3} - \frac{3T}{2} \cdot \frac{(x - \mu)^2 - \sigma^2}{\sigma^2}$. Requer
 $\int x^6 dF < \infty$ para $\tau^2 < \infty$.

Quantil (truque) derivar $(1 - \varepsilon)F(\xi_p(\varepsilon)) + \varepsilon \mathbb{I}(x \leq \xi_p(\varepsilon)) = p$ em $\varepsilon = 0$.

Normalidade assintótica

(A1) von Mises $T(G) - T(F) = \int \text{IF} d(G - F) + R(G, F)$,

$\sqrt{n}R(\hat{F}_n, F) \xrightarrow{P} 0, \tau^2 = \int \text{IF}^2 dF \in (0, \infty)$.

Teorema $\sqrt{n}(T(\hat{F}_n) - T(F)) = \frac{1}{\sqrt{n}} \sum \text{IF}(X_i) + o_P(1) \xrightarrow{d} N(0, \tau^2)$.

EP e IC $\hat{\tau}^2 = n^{-1} \sum \hat{\text{IF}}(X_i)^2$; $T(\hat{F}_n) \pm z_{1-\alpha/2} \hat{\tau} / \sqrt{n}$.

Mediana $\sqrt{n}(\hat{m} - m) \xrightarrow{d} N\left(0, \frac{1}{4f(m)^2}\right)$ (exige estimar f).

Robustez sensibilidade a erros grosseiros $\sup_x |\text{IF}(x)|$: média ∞ , mediana $1/(2f(m))$.

Jackknife e Bootstrap (Aula 6)

Exclusão $\hat{\theta}_{-i} = T(\hat{F}_{n, -i}), \bar{\theta} = n^{-1} \sum \hat{\theta}_{-i}$.

Jackknife $\hat{b}_{\text{jack}} = (n - 1)(\bar{\theta} - \hat{\theta}_n)$, $\hat{\theta}_{\text{jack}} = n\hat{\theta}_n - (n - 1)\bar{\theta}$.

(A1) $\mathbb{E}\hat{\theta}_n = \theta + \frac{a}{n} + \frac{b}{n^2} + O(n^{-3}) \Rightarrow \mathbb{E}\hat{\theta}_{\text{jack}} = \frac{a}{n} + O(n^{-2})$,
 $\mathbb{E}\hat{\theta}_{\text{jack}} - \theta = O(n^{-2})$. Se o viés é *exatamente* a/n : $\hat{\theta}_{\text{jack}}$ é não-viesado.

Pseudo-valores $\tilde{\theta}_i = n\hat{\theta}_n - (n - 1)\hat{\theta}_{-i}$; $\hat{\theta}_{\text{jack}} = \bar{\tilde{\theta}}$;
 $\hat{v}_{\text{jack}} = \frac{n-1}{n} \sum (\hat{\theta}_{-i} - \bar{\theta})^2 = \frac{n(1-n)}{n} \sum (\tilde{\theta}_i - \bar{\tilde{\theta}})^2$.

Identidades $\bar{X}_{-i} = \frac{n\bar{X} - X_i}{n-1}$; $\bar{X}_{-i} - \bar{X} = \frac{\bar{X} - X_i}{n-1}$;
 $\sum_i (\bar{X}_{-i} - \bar{X})^2 = \frac{n\hat{\sigma}^2}{(n-1)^2}$; $\mathbb{E}\bar{X}^2 = \mu^2 + \frac{\sigma^2}{n}$.

Média $\hat{b}_{\text{jack}} = 0, \hat{v}_{\text{jack}} = S^2/n$ (S^2 com $n - 1$).

μ^2 $\hat{\theta} = \bar{X}^2$: $a = \sigma^2, b = 0$; $\bar{\theta} = \frac{1}{n} \sum \bar{X}_{-i} = \bar{X}^2 + \frac{\hat{\sigma}^2}{(n-1)^2}$,

$\hat{\theta}_{\text{jack}} = \bar{X}^2 - \frac{\hat{\sigma}^2}{n-1}$ (não-viesado).

Amostra bootstrap $X_1^*, \dots, X_n^*$ i.i.d. $\sim \hat{F}_n; \hat{\theta}^* = T(\hat{F}_n^*)$. O bootstrap é o plug-in de funcionais como $se_F(\hat{\theta})$.

Viés / EP $\hat{b}^* = \mathbb{E}^* \hat{\theta}^* - \hat{\theta}_n$; corrigido $2\hat{\theta}_n - \bar{\theta}^*$. $\widehat{se}_{\text{boot}}^2 = \frac{1}{B} \sum_b (\hat{\theta}_b^* - \bar{\theta}^*)^2$ (Monte Carlo para $\mathbb{V}^*$).

Momentos sob $\hat{F}_n$ $\mathbb{E}^* \bar{X}^* = \bar{X}$, $\mathbb{V}^* \bar{X}^* = \hat{\sigma}^2/n$, $\mathbb{E}^*(\bar{X}^*)^2 = \bar{X}^2 + \hat{\sigma}^2/n$. Para $\bar{X}^2$: $\hat{b}^* = \hat{\sigma}^2/n$; $\bar{X}^2 - \hat{\sigma}^2/n$ tem viés σ^2/n^2 .

Intervalo t $\hat{\theta}_n \pm z_{1-\alpha/2} \widehat{se}_{\text{boot}}$.

Percentil $[q_{\alpha/2}^*, q_{1-\alpha/2}^*]$ (quantis das réplicas).

Consistência $\mathbb{V} X_1 < \infty$, média:

$$\sup_x |\mathbb{P}^*(\sqrt{n}(\hat{\theta}^* - \hat{\theta}_n) \leq x) - \mathbb{P}(\sqrt{n}(\hat{\theta}_n - \theta) \leq x)| \stackrel{q.c.}{\rightarrow} 0.$$

Contagem amostras ordenadas: n^n ; multiconjuntos distintos:

$$\binom{2n-1}{n} = \frac{(2n-1)!}{n!(n-1)!} \text{ (estrelas e barras: } n \text{ bolas em } n \text{ caixas).}$$

Estimação de densidade

Histograma (Aula 1)

Definição $[0, 1]$ em m intervalos de comprimento $h = 1/m$:

$$\hat{f}_n(x) = \frac{1}{nh} \sum_i \mathbb{I}(X_i \in B_j), x \in B_j; p_j = \int_{B_j} f.$$

Momentos $\mathbb{E} \hat{f}_n(x) = p_j/h$; $\mathbb{V} \hat{f}_n(x) = \frac{p_j(1-p_j)}{nh^2}$.

(A1) $|f'| \leq L \Rightarrow |f(u) - f(x)| \leq L|u - x|$.

Viés $|\mathbb{E} \hat{f}_n(x) - f(x)| \leq Lh$. **Cota** $f \leq 1 + L/2$ (integrar $f(x) \leq f(y) + L|x - y|$ em y).

Variância $\mathbb{V} \hat{f}_n(x) \leq \frac{f(x)+Lh}{nh} \leq \frac{1+L/2+Lh}{nh}$.

Risco $MSE \leq L^2 h^2 + \frac{1+L/2}{nh} + \frac{L}{n}$; $MISE \leq L^2 h^2 + \frac{1}{nh} + \frac{L}{n}$; $h \asymp n^{-1/3}$, taxa $n^{-2/3}$.

KDE (Aula 7)

Hölder $\Sigma(\beta, L)$ $\ell =$ maior inteiro $< \beta$; f ℓ vezes diferenciável,

$$|f^{(\ell)}(y) - f^{(\ell)}(x)| \leq L|y - x|^{\beta-\ell}.$$

Taylor $f(x+t) = \sum_{j=0}^{\ell} \frac{f^{(j)}(x)}{j!} t^j + R_x(t)$, $|R_x(t)| \leq \frac{L}{\ell!} |t|^\beta$.

Kernel $\int K = 1$, $R(K) = \int K^2 < \infty$; $\kappa_j = \int |u|^j |K(u)| du$.

Ordem k $\kappa_k < \infty$ e $\int u^j K = 0$, $1 \leq j \leq k$. Simétrico + $\kappa_1 < \infty \Rightarrow$ ordem 1. Para $\Sigma(\beta, L)$ usar ordem ℓ ; $\beta \leq 1$: nenhum momento precisa anular.

KDE $\hat{f}_n(x) = \frac{1}{nh} \sum_i K\left(\frac{X_i - x}{h}\right)$.

Momentos $\mathbb{E} \hat{f}_n(x) = \int K(u) f(x + uh) du$;
 $\mathbb{V} \hat{f}_n(x) \leq \frac{1}{nh} \int K(u)^2 f(x + uh) du \leq \frac{\sup f R(K)}{nh}$.

Viés $\mathbb{E} \hat{f}_n(x) - f(x) = \int K(u) R_x(uh) du$, $|\cdot| \leq \frac{L \kappa_\beta}{\ell!} h^\beta$.

f limitada K limitado de ordem ℓ , $\kappa_\beta < \infty$:

$$f(x) = \int K(u) f(x + u) du - \int K R_x \Rightarrow f \leq \sup |K| + \frac{L \kappa_\beta}{\ell!}.$$

Risco $MSE(\hat{f}_n(x)) \leq C \left(h^{2\beta} + \frac{1}{nh}\right)$;

$$h = n^{-1/(2\beta+1)} \Rightarrow \sup_x MSE \leq 2C n^{-\frac{2\beta}{2\beta+1}}. \text{ (}\beta = 1: n^{-2/3}; \beta = 2: n^{-4/5}\text{.)}$$

Kernel	$K(u)$	κ_2	$R(K)$
Uniforme	$\frac{1}{2} \mathbb{I}(u \leq 1)$	$\frac{1}{3}$	$\frac{1}{2}$
Epanechnikov	$\frac{3}{4} (1 - u^2) \mathbb{I}(u \leq 1)$	$\frac{1}{5}$	$\frac{3}{5}$
Gaussiano	$(2\pi)^{-1/2} e^{-u^2/2}$	1	$\frac{1}{2\sqrt{\pi}}$

Regra geral de taxas

d dimensões, derivada s viés $\asymp h^{\beta-s}$, variância $\asymp (nh^{d+2s})^{-1}$

$$\Rightarrow h^* \asymp n^{-\frac{1}{2\beta+d}}, MSE \asymp n^{-\frac{2(\beta-s)}{2\beta+d}}.$$

KDE bivariado $\hat{f}_h(x, z) = \frac{1}{nh^2} \sum K(\frac{X_i - x}{h}) K(\frac{Z_i - z}{h})$;

$\mathbb{E} \hat{f}_h = \iint K(u) K(v) f(x + uh, z + vh) du dv$. Com

$$|f(x, z) - f(x', z')| \leq L(|x - x'|^\beta + |z - z'|^\beta), \beta \leq 1: \text{viés}$$

$$\leq 2L \kappa_0 \kappa_\beta h^\beta; \text{variância} \leq \frac{\sup f R(K)^2}{nh^2}; f \leq 1 + \frac{2L}{\beta+1} \text{ (integrar em}$$

$$[x, x+1] \times [z, z+1]). h \asymp n^{-\frac{1}{2\beta+2}}, MSE \asymp n^{-\frac{\beta}{\beta+1}} \text{ (pior que } n^{-\frac{2\beta}{2\beta+1}} \text{: maldição da dimensão).}$$

Derivada s (Tsybakov 1.2) $\hat{p}_{n,s} = \frac{1}{nh^{s+1}} \sum K(\frac{X_i - x}{h})^s, \int u^s K = s!$: viés $\leq ch^{\beta-s}$, $\mathbb{V} \leq c'(nh^{2s+1})^{-1}$.

Estimação não-viesada do risco (Aula 8)

Decomposição $MISE(h) = A(h) - 2B(h) + \int f^2$, $A = \mathbb{E} \int \hat{f}_n^2$,

$$B = \mathbb{E} \int \hat{f}_n f. \text{ Minimizar } J(h) = A - 2B.$$

Termos $\int \hat{f}_n^2$ é não-viesado para A .

$$B(h) = \mathbb{E} \hat{f}_h(X_{n+1}) = \frac{1}{h} \mathbb{E} K\left(\frac{X_2 - X_1}{h}\right).$$

Estimador ingênuo $\mathbb{E}\left[\frac{1}{n} \sum \hat{f}_n(X_i)\right] = \frac{K(0)}{nh} + \frac{n-1}{n} B(h)$ (viesado).

LOO $\hat{f}_{h,-i}(x) = \frac{1}{(n-1)h} \sum_{j \neq i} K(\frac{X_j - x}{h})$.

CV $CV(h) = \int \hat{f}_h^2 - \frac{2}{n} \sum_i \hat{f}_{h,-i}(X_i)$;

$$\mathbb{E} CV(h) = J(h) = MISE(h) - \int f^2.$$

Cálculo $\bar{K}(v) = \int K(t) K(t+v) dt$:

$$CV(h) = \frac{1}{n^2 h} \sum_{i,j} \bar{K}\left(\frac{X_j - X_i}{h}\right) - \frac{2}{n(n-1)h} \sum_{i \neq j} K\left(\frac{X_j - X_i}{h}\right).$$

Gaussiano: $\bar{K}$ = densidade $N(0, 2)$.

Regressão: linear smoothers (Aulas 9–10)

Modelo $Y_i = r(X_i) + \varepsilon_i$, $r(x) = \mathbb{E}[Y \mid X = x]$, $\mathbb{E}[\varepsilon \mid X] = 0$, $\mathbb{V}[\varepsilon \mid X] = \sigma^2$.

MQ $\hat{\beta} = (\mathbb{X}^T \mathbb{X})^{-1} \mathbb{X}^T \mathbf{Y}$; $\ell_i(x) = x^T (\mathbb{X}^T \mathbb{X})^{-1} X_i$, $\sum \ell_i = 1$ (com intercepto).

Ridge $\hat{\beta}_\lambda = (\mathbb{X}^T \mathbb{X} + \lambda I)^{-1} \mathbb{X}^T \mathbf{Y}$.

Linear smoother $\hat{r}_n(x) = \sum_i \ell_i(x) Y_i$, ℓ depende de x e dos X_i , não dos Y_i .

Matriz $L_{ij} = \ell_j(X_i)$, $\hat{\mathbf{r}} = \mathbf{L} \mathbf{Y}$; $\nu = \text{tr}(\mathbf{L})$. MQ: $\nu = p$.

Método	$\ell_i(x)$
Regressograma	$\mathbb{I}(X_i \in B_j)/n_j, x \in B_j$
k -NN	$\mathbb{I}(i \in N_k(x))/k$
Médias locais	$\mathbb{I}(X_i - x \text{ em } (-h, h))/\sum_s (\cdot)$
Nadaraya-Watson	$K(\frac{X_i - x}{h})/\sum_s K(\frac{X_s - x}{h})$
Pol. local grau q	$\frac{1}{nh} K(Z_i e_1^T B_x^{-1} U(Z_i)$
Proc. gaussiano	$[\mathbf{c}(x)^T (\mathbf{C} + \sigma^2 I)^{-1}]_i$

Pol. local $Z_i = \frac{X_i - x}{h}$, $U(u) = (1, u, \frac{u^2}{2!}, \dots, \frac{u^q}{q!})^T$,

$$B_x = \frac{1}{nh} \sum K(Z_i) U(Z_i) U(Z_i)^T. \text{ Reproducez polinômios: } \sum \ell_i = 1,$$

$$\sum \ell_i (X_i - x)^j = 0, 1 \leq j \leq q. q = 0: \text{Nadaraya-Watson.}$$

Cond. ao desenho $\mathbb{E}[\hat{r}_n(x) \mid \mathbf{X}] = \sum \ell_i(x) r(X_i)$;
 $\mathbb{V}[\hat{r}_n(x) \mid \mathbf{X}] = \sigma^2 \|\ell(x)\|^2$. Se $\sum \ell_i = 1$: viés = $\sum \ell_i(x) (r(X_i) - r(x))$.

Risco de linear smoothers

(A1) $r \in \Sigma(\beta, L)$, $m =$ maior inteiro $< \beta$.

(A2) (P1) $\sum \ell_i = 1$, $\sum \ell_i (X_i - x)^j = 0$, $1 \leq j \leq m$; (P2) $\ell_i(x) = 0$ se $|X_i - x| > h$; (P3) $\sum |\ell_i| \leq C_0$, $\max |\ell_i| \leq \frac{C_0}{nh}$.

Teorema viés $\leq \frac{L C_0}{m!} h^\beta$, $\mathbb{V} \leq \frac{\sigma^2 C_0^2}{nh}$, risco cond. $\leq C(h^{2\beta} + \frac{1}{nh})$;

$h = n^{-1/(2\beta+1)}$: $2C n^{-\frac{2\beta}{2\beta+1}}$. (P1) $\leftrightarrow$ ordem do kernel; (P2) $\leftrightarrow$ suporte; (P3) $\leftrightarrow \kappa_\beta, R(K)$.

Regressograma r L -Lipschitz, $n_j \geq c_0 n h$: viés $\leq Lh$, $\mathbb{V} \leq \frac{\sigma^2}{n_j} \leq \frac{\sigma^2}{c_0 n h}$, $MSE \rightarrow 0$ se $h_n \rightarrow 0$ e $n h_n \rightarrow \infty$.

Nadaraya-Watson $0 \leq K \leq K_{\max}$, suporte $[-1, 1]$, $\beta \leq 1$,

$$\sum_s K(\frac{X_s - x}{h}) \geq c_0 n h: C_0 = \max(1, K_{\max}/c_0).$$

Pol. local $q \geq m$; (D1) $\lambda_{\min}(B_x) \geq \lambda_0$; (D2) $\#\{|X_i - x| \leq h\} \leq a_0 n h$: $|\ell_i| \leq \frac{K_{\max} \sqrt{q+1}}{\lambda_0 n h}$. $B_x \rightarrow f(x)$, $\mathbf{B} = \int K U U^T$.

Kernel equivalente $K^*(u) = e_1^T \mathbf{B}^{-1} U(u) K(u)$ é kernel de ordem q .

Escolha de banda e inferência

CV $CV = \frac{1}{n} \sum (Y_i - \hat{r}_{-i}(X_i))^2$.

Atalho Pesos normalizados $\ell_j = g_j / \sum_s g_s$ ou MQ:

$$Y_i - \hat{r}_{-i}(X_i) = \frac{Y_i - \hat{r}_n(X_i)}{1 - L_{ii}}.$$

Sherman-Morrison $(A - v v^T)^{-1} = A^{-1} + \frac{A^{-1} v v^T A^{-1}}{1 - v^T A^{-1} v}$.

GCV $\frac{1}{n} \sum \left(\frac{Y_i - \hat{r}_n(X_i)}{1 - \nu/n}\right)^2$.

Risco no desenho $\mathcal{R}_n = \frac{1}{n} \mathbb{E}[\|\hat{\mathbf{r}} - \mathbf{r}\|^2 \mid \mathbf{X}]$.

Formas quadráticas $\mathbb{E}[\|\mathbf{v} + M \boldsymbol{\varepsilon}\|^2 \mid \mathbf{X}] = \|\mathbf{v}\|^2 + \sigma^2 \text{tr}(M^T M)$.

C_p de Mallows $\hat{C}_p = \frac{1}{n} \|\mathbf{Y} - \mathbf{L} \mathbf{Y}\|^2 + \frac{2\sigma^2 \nu}{n}$, $\mathbb{E}[\hat{C}_p \mid \mathbf{X}] = \mathcal{R}_n + \sigma^2$.

IC erros $N(0, \sigma^2)$: $\hat{r}_n(x) \pm z_{1-\alpha/2} \sigma \|\ell(x)\|$ cobre $\mathbb{E}[\hat{r}_n(x) \mid \mathbf{X}]$ (não $r(x)$: viés!).

Receitas para a prova

Consistência q.c. Lipschitz em $\|\cdot\|_\infty \Rightarrow |T(\hat{F}_n) - T(F)| \leq L D_n \Rightarrow$ GC/DKW. Taxa via $D_n \leq 2\sqrt{\log n/n}$.

VC Fragmentar d pontos explícitos; para $d + 1$, ordenar e achar rótulo impossível; concluir GC por Sauer + desigualdade VC.

IF $\rightarrow$ IC Calcular IF (cadeia/quociente), checar $\int \text{IF} dF = 0$, $\tau^2 = \mathbb{E} \text{IF}^2$, momentos necessários, IC de Wald.

Viés/variância/MSE (1) $\mathbb{E}$ como integral; (2) $u = (y - x)/h$; (3) centrar com $\int K = 1$; (4) Taylor/Hölder; (5) variância $\leq \mathbb{E} Z^2$; (6) equilibrar h .

Jackknife calcular $\hat{\theta}_{-i}$ via $\bar{X}_{-i}$, somar, comparar com (A1).

Armadilhas $\hat{\sigma}^2(n)$ vs. $S^2(n - 1)$; ℓ vs. m (inteiro *estritamente* menor); taxa depende de d ; resultados de regressão são *condicionais* a $\mathbf{X}$.