

Formulário resumido – Estatística Não-Paramétrica

Convenção: $X_1, \dots, X_n$ i.i.d. com função de distribuição (FD) F . Toda função aparece com o seu argumento: $F(x)$, $g(x)$, $K(u)$, etc.

Ferramentas

Chebyshev Se $\mathbb{E}[T] = \theta$: $\mathbb{P}(|T - \theta| \geq t) \leq \frac{\mathbb{V}(T)}{t^2}$.

Hoeffding $Y_1, \dots, Y_n$ independentes com $Y_i \in [0, 1]$, $\bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i$:

$$\mathbb{P}(|\bar{Y} - \mathbb{E}[\bar{Y}]| \geq \varepsilon) \leq 2e^{-2n\varepsilon^2}.$$

Borel-Cantelli Se $\sum_n \mathbb{P}(|T_n - \theta| > \varepsilon) < \infty$ para todo $\varepsilon > 0$, então $T_n \xrightarrow{q.c.} \theta$.

Uso: toda cota do tipo $Ce^{-c n \varepsilon^2}$ é somável em n , logo dá convergência quase certa.

Método delta Se $\sqrt{n}(Y_n - \mu) \xrightarrow{d} N(0, \sigma^2)$ e g é derivável em μ :

$$\sqrt{n}(g(Y_n) - g(\mu)) \xrightarrow{d} N(0, g'(\mu)^2 \sigma^2).$$

Viés e variância $\text{MSE}(\hat{\theta}) = \mathbb{E}[(\hat{\theta} - \theta)^2] = (\mathbb{E}[\hat{\theta}] - \theta)^2 + \mathbb{V}(\hat{\theta})$.

Distribuição empírica

Definição $\hat{F}_n(x) = \frac{1}{n} \sum_{i=1}^n \mathbb{I}(X_i \leq x)$, para cada $x \in \mathbb{R}$.

Num ponto x fixo $n\hat{F}_n(x) \sim \text{Binomial}(n, F(x))$, logo

$$\mathbb{E}[\hat{F}_n(x)] = F(x), \quad \mathbb{V}[\hat{F}_n(x)] = \frac{F(x)(1 - F(x))}{n} \leq \frac{1}{4n}.$$

Erro máximo $D_n = \sup_{x \in \mathbb{R}} |\hat{F}_n(x) - F(x)|$.

Glivenko-Cantelli $D_n \xrightarrow{q.c.} 0$.

DKW $\mathbb{P}(D_n \geq \varepsilon) \leq 2e^{-2n\varepsilon^2}$, para todo $\varepsilon > 0$.
Consequência: quase certamente, $D_n = O(\sqrt{\log n/n})$.

Molde: consistência por Lipschitz

Se existe $L > 0$ tal que, para quaisquer FDs G_1, G_2 ,

$$|T(G_1) - T(G_2)| \leq L \sup_x |G_1(x) - G_2(x)|,$$

então $|T(\hat{F}_n) - T(F)| \leq L D_n \xrightarrow{q.c.} 0$.

Exemplo: $T(F) = \int_0^M F(x)^2 dx$. Como $|a^2 - b^2| = |a + b||a - b| \leq 2|a - b|$ para $a, b \in [0, 1]$, vale $L = 2M$.

Molde: mediana amostral

Se a densidade satisfaz $f(x) \geq C_1 > 0$, então $|F(x) - F(y)| \geq C_1|x - y|$. Daí

$$|\hat{m}_n - m| \leq \frac{D_n + n^{-1}}{C_1} \xrightarrow{q.c.} 0.$$

Dimensão VC

$\mathcal{C}$ é uma classe de conjuntos e $A = \{x_1, \dots, x_k\}$ é um conjunto finito de pontos.

Fragmentar $\mathcal{C}$ fragmenta A se *toda* subconjunto de A é da forma $C \cap A$ para algum $C \in \mathcal{C}$.

Dimensão VC $\text{VC}(\mathcal{C})$ = o maior k tal que *algum* conjunto de k pontos é fragmentado.

Coefficiente $s(\mathcal{C}, n)$ = número máximo de subconjuntos distintos $C \cap A$, entre conjuntos A com n pontos.

Sauer-Shelah Se $\text{VC}(\mathcal{C}) = d$, então $s(\mathcal{C}, n) \leq (n + 1)^d$.

Desigualdade de VC Com $P_n(C) = \frac{1}{n} \sum_i \mathbb{I}(X_i \in C)$:

$$\mathbb{P}\left(\sup_{C \in \mathcal{C}} |P_n(C) - P(C)| > \varepsilon\right) \leq 8 s(\mathcal{C}, n) e^{-n\varepsilon^2/32}.$$

Com Sauer-Shelah e Borel-Cantelli:
 $\text{VC} < \infty \Rightarrow \sup_C |P_n(C) - P(C)| \xrightarrow{q.c.} 0$.

Classe $\mathcal{C}$	$\text{VC}(\mathcal{C})$
semirretas $(-\infty, a]$ em $\mathbb{R}$	1
intervalos $[a, b]$ em $\mathbb{R}$	2
retângulos $[a_1, b_1] \times [a_2, b_2]$	4
semiespaços em $\mathbb{R}^d$	$d + 1$

Receita para mostrar VC = d: (i) exiba *um* conjunto de d pontos e todos os seus subconjuntos; (ii) para *qualquer* conjunto de $d + 1$ pontos, ordene $x_1 < \dots < x_{d+1}$ e encontre um subconjunto que nenhum C produz.

Funcionais e função de influência

Funcional Uma função T que recebe uma FD e devolve um número: $\theta = T(F)$. O estimador plug-in é $T(\hat{F}_n)$.

Funcional linear Existe uma função $g : \mathbb{R} \rightarrow \mathbb{R}$ tal que

$$T(F) = \int g(x) dF(x) = \mathbb{E}_F[g(X)].$$

O plug-in é a média amostral de g : $T(\hat{F}_n) = \frac{1}{n} \sum_{i=1}^n g(X_i)$.
Exemplos: média, $g(x) = x$; $F(t)$, $g(x) = \mathbb{I}(x \leq t)$.

Massa pontual em x_0 É a FD de uma v.a. constante igual a x_0 :

$$\delta_{x_0}(y) = \mathbb{I}(y \geq x_0), \quad y \in \mathbb{R}.$$

Contaminação Para $\varepsilon \in [0, 1]$, a FD

$$F_\varepsilon(y) = (1 - \varepsilon)F(y) + \varepsilon \delta_{x_0}(y), \quad y \in \mathbb{R},$$

sorteia de F com prob. $1 - \varepsilon$ e devolve x_0 com prob. ε .

Função de influência Efeito em T de uma observação extra em x_0 :

$$\text{IF}(x_0) = \lim_{\varepsilon \downarrow 0} \frac{T(F_\varepsilon) - T(F)}{\varepsilon} = \frac{d}{d\varepsilon} T(F_\varepsilon) \Big|_{\varepsilon=0}.$$

Sempre vale $\int \text{IF}(x) dF(x) = 0$: use para conferir a conta.

$T(F)$	$\text{IF}(x)$
$\int g(y) dF(y)$	$g(x) - T(F)$
média μ	$x - \mu$
variância σ^2	$(x - \mu)^2 - \sigma^2$
quantil ξ_p	$\frac{p - \mathbb{I}(x \leq \xi_p)}{f(\xi_p)}$

Regra da cadeia Se $T(F) = h(\theta_1, \dots, \theta_k)$ com $\theta_j = \int g_j(y) dF(y)$:

$$\text{IF}(x) = \sum_{j=1}^k \frac{\partial h}{\partial \theta_j}(\theta_1, \dots, \theta_k) (g_j(x) - \theta_j).$$

Normalidade assintótica Sob regularidade (expansão de von Mises),

$$\sqrt{n}(T(\hat{F}_n) - T(F)) \xrightarrow{d} N(0, \tau^2), \quad \tau^2 = \int \text{IF}(x)^2 dF(x).$$

Intervalo de confiança $\hat{\tau}^2 = \frac{1}{n} \sum_{i=1}^n \widehat{\text{IF}}(X_i)^2$ e $T(\hat{F}_n) \pm z_{1-\alpha/2} \hat{\tau}/\sqrt{n}$.

Jackknife e bootstrap

$\hat{\theta}_n = T(\hat{F}_n)$; $\hat{\theta}_{-i}$ é o mesmo estimador calculado *sem* X_i ;

$$\bar{\theta} = \frac{1}{n} \sum_{i=1}^n \hat{\theta}_{-i}.$$

Jackknife Viés: $\hat{b}_{\text{jack}} = (n - 1)(\bar{\theta} - \hat{\theta}_n)$.

Estimador corrigido: $\hat{\theta}_{\text{jack}} = \hat{\theta}_n - \hat{b}_{\text{jack}} = n\hat{\theta}_n - (n - 1)\bar{\theta}$.

Variância: $\hat{v}_{\text{jack}} = \frac{n-1}{n} \sum_{i=1}^n (\hat{\theta}_{-i} - \bar{\theta})^2$.

Por que funciona Se $\mathbb{E}[\hat{\theta}_n] = \theta + \frac{a}{n} + \frac{b}{n^2} + \dots$, então o viés de $\hat{\theta}_{\text{jack}}$ é $O(n^{-2})$.

Identidade útil $\bar{X}_{-i} = \frac{n\bar{X} - X_i}{n - 1}$.

Bootstrap Sorteie $X_1^*, \dots, X_n^*$ com reposição de $X_1, \dots, X_n$ e calcule $\hat{\theta}^*$. Repita B vezes: $\hat{\theta}_1^*, \dots, \hat{\theta}_B^*$.

Erro padrão $\hat{\text{s}}\hat{\text{c}}_{\text{boot}}^2 = \frac{1}{B} \sum_{b=1}^B (\hat{\theta}_b^* - \bar{\theta}^*)^2$, $\bar{\theta}^* = \frac{1}{B} \sum_b \hat{\theta}_b^*$.

Viés $\hat{b}^* = \bar{\theta}^* - \hat{\theta}_n$.

Intervalos normal: $\hat{\theta}_n \pm z_{1-\alpha/2} \hat{\text{s}}\hat{\text{c}}_{\text{boot}}$; percentil: quantis $\alpha/2$ e $1 - \alpha/2$ dos $\hat{\theta}_b^*$.

Estimador de densidade por kernel

Kernel $K : \mathbb{R} \rightarrow \mathbb{R}$ com $\int K(u) du = 1$. Ordem k : $\int u^j K(u) du = 0$ para $j = 1, \dots, k$ (todo kernel simétrico tem ordem 1).

KDE Com banda $h > 0$:

$$\hat{f}_n(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{X_i - x}{h}\right).$$

Esperança Trocando $u = (y - x)/h$:

$$\mathbb{E}[\hat{f}_n(x)] = \int K(u) f(x + uh) du.$$

Suavidade (Hölder) $f \in \Sigma(\beta, L)$: com ℓ o maior inteiro $< \beta$, $|f^{(\ell)}(y) - f^{(\ell)}(x)| \leq L|y - x|^{\beta-\ell}$. Para $\beta \leq 1$: $|f(y) - f(x)| \leq L|y - x|^\beta$.

Viés Kernel de ordem ℓ com $\int |u|^\beta |K(u)| du < \infty$:

$$|\mathbb{E}[\hat{f}_n(x)] - f(x)| \leq C h^\beta.$$

Variância f limitada e $\int K(u)^2 du < \infty$: $\mathbb{V}[\hat{f}_n(x)] \leq \frac{C}{nh}$.

Banda ótima $\text{MSE} \leq C(h^{2\beta} + \frac{1}{nh})$. Igualando os termos:

$$h \asymp n^{-1/(2\beta+1)}, \quad \text{MSE} \asymp n^{-2\beta/(2\beta+1)}.$$

Em d dimensões variância $\asymp \frac{1}{nh^d}$, logo $h \asymp n^{-1/(2\beta+d)}$ e $\text{MSE} \asymp n^{-2\beta/(2\beta+d)}$.

Validação cruzada $\hat{f}_{-i}$ é o KDE sem X_i :

$$\text{CV}(h) = \int \hat{f}_n(x)^2 dx - \frac{2}{n} \sum_{i=1}^n \hat{f}_{-i}(X_i),$$

e $\mathbb{E}[\text{CV}(h)] = \mathbb{E} \int (\hat{f}_n(x) - f(x))^2 dx - \int f(x)^2 dx$.

Roteiro para viés/variância/MSE

1. Escrever a esperança como integral em y .
2. Trocar $u = (y - x)/h$.
3. Usar $\int K(u) du = 1$ para subtrair $f(x)$ dentro da integral.
4. Cotar $|f(x + uh) - f(x)|$ pela suavidade.

5. Variância: $\mathbb{V}(Z) \leq \mathbb{E}[Z^2]$.
6. Igualar viés² e variância para achar h .

Regressão: linear smoothers

Modelo: $Y_i = r(X_i) + \varepsilon_i$, $\mathbb{E}[\varepsilon_i \mid X_i] = 0$, $\mathbb{V}[\varepsilon_i \mid X_i] = \sigma^2$.

Linear smoother $\hat{r}_n(x) = \sum_{i=1}^n \ell_i(x) Y_i$, com pesos $\ell_i(x)$ que dependem de x e dos X_i , mas não dos Y_i .

Nadaraya-Watson $\ell_i(x) = \frac{K((X_i - x)/h)}{\sum_{s=1}^n K((X_s - x)/h)}$.

Regressograma $\ell_i(x) = \mathbb{I}(X_i \in B_j)/n_j$ se $x \in B_j$, com $n_j = \#\{i : X_i \in B_j\}$.

Viés e variância (dado $\mathbf{X}$) Se $\sum_i \ell_i(x) = 1$:

$$\mathbb{E}[\hat{r}_n(x) \mid \mathbf{X}] - r(x) = \sum_{i=1}^n \ell_i(x) (r(X_i) - r(x)),$$

$$\mathbb{V}[\hat{r}_n(x) \mid \mathbf{X}] = \sigma^2 \sum_{i=1}^n \ell_i(x)^2.$$

Mesma taxa do KDE Se os pesos são locais ($\ell_i(x) = 0$ quando $|X_i - x| > h$) e $|\ell_i(x)| \leq \frac{C}{nh}$: viés $\leq Ch^\beta$, variância $\leq \frac{C}{nh}$.

Validação cruzada Para Nadaraya-Watson, regressograma e MQ, com $L_{ii} = \ell_i(X_i)$:

$$\text{CV} = \frac{1}{n} \sum_{i=1}^n \left(\frac{Y_i - \hat{r}_n(X_i)}{1 - L_{ii}} \right)^2.$$