

Formulário resumido – Estatística Não-Paramétrica

Convenções. $X_1, \dots, X_n$ i.i.d. com função de distribuição (FD) F . Toda função aparece com o seu argumento: $F(y)$, $g(y)$, $K(u)$, etc. A letra y é sempre a variável de integração ou o argumento de uma FD; x_0 é um ponto fixo.

Ordens

$b_n > 0$ é uma sequência determinística.

Números Para viés, variância, MSE, $\mathbb{E}[\cdot]$, $\mathbb{P}(\cdot)$, com $a_n \geq 0$: $a_n = O(b_n)$ se existe $C > 0$, que não depende de n , com $a_n \leq C b_n$ para n grande; $a_n = o(b_n)$ se $a_n/b_n \rightarrow 0$. O mesmo vale com $h \rightarrow 0$ no lugar de $n \rightarrow \infty$, e com C que não depende de x (cota uniforme).

V.a., trajetória a trajetória $Z_n = O(b_n)$ q.c. se, para quase todo ω , a sequência de números $|Z_n(\omega)|$ é $O(b_n)$.

V.a., em probabilidade $Z_n = O_P(b_n)$ se, para todo $\eta > 0$, existem M, N com $\mathbb{P}(|Z_n| > M \mid b_n) < \eta$ para todo $n \geq N$; $Z_n = o_P(b_n)$ se $Z_n/b_n \xrightarrow{P} 0$.

Relações $Z_n = O(b_n)$ q.c. $\Rightarrow Z_n = O_P(b_n)$. Se $b_n \rightarrow 0$: $O(b_n)$ q.c. $\Rightarrow Z_n \xrightarrow{q.c.} 0$, e $O_P(b_n) \Rightarrow Z_n \xrightarrow{P} 0$ (mas não $\xrightarrow{q.c.}$).

Convergência

Em probabilidade $X_n \xrightarrow{P} X$ se, para todo $\varepsilon > 0$, $\mathbb{P}(|X_n - X| > \varepsilon) \rightarrow 0$ quando $n \rightarrow \infty$.

Quase certa $X_n \xrightarrow{q.c.} X$ se $\mathbb{P}(\lim_{n \rightarrow \infty} |X_n - X| = 0) = 1$.

Quase certa (eventos de cauda) Equivalentemente, para todo $\varepsilon > 0$,

$$\mathbb{P}(|X_n - X| > \varepsilon \text{ infinitas vezes}) = 0,$$

em que $\{A_n \text{ i.v.}\} = \limsup_n A_n = \bigcap_{m \geq 1} \bigcup_{n \geq m} A_n$. Também equivale a $\mathbb{P}(\sup_{n \geq m} |X_n - X| > \varepsilon) \rightarrow 0$ quando $m \rightarrow \infty$.

Em distribuição $X_n \xrightarrow{d} X$ se $\mathbb{P}(X_n \leq t) \rightarrow \mathbb{P}(X \leq t)$ em todo ponto t de continuidade de $t \mapsto \mathbb{P}(X \leq t)$.

Relações $X_n \xrightarrow{q.c.} X \Rightarrow X_n \xrightarrow{P} X \Rightarrow X_n \xrightarrow{d} X$; e $X_n \xrightarrow{d} c$ (constante) $\Rightarrow X_n \xrightarrow{P} c$.

Ferramentas

Markov Denotando $\nu_{nr} = \mathbb{E}|T_n - \theta|^r < \infty$, para algum $r > 0$, vale, para $t > 0$,

$$\mathbb{P}(|T_n - \theta| > t) \leq \frac{\nu_{nr}}{t^r}.$$

Chebyshev Caso $r = 2$ com $\mathbb{E}[T_n] = \theta$: $\mathbb{P}(|T_n - \theta| > t) \leq \frac{\mathbb{V}(T_n)}{t^2}$.

Hoeffding $Y_1, \dots, Y_n$ independentes, $\mathbb{E}[Y_i] = 0$ e $a_i \leq Y_i \leq b_i$. Para $\varepsilon > 0$ e qualquer $t > 0$,

$$\mathbb{P}\left(\sum_{i=1}^n Y_i \geq \varepsilon\right) \leq e^{-t\varepsilon} \prod_{i=1}^n e^{t^2(b_i - a_i)^2/8}.$$

Escolhendo $t = 4\varepsilon / \sum_i (b_i - a_i)^2$: $\leq \exp(-2\varepsilon^2 / \sum_i (b_i - a_i)^2)$.
Caso das aulas: $Y_i \in [0, 1]$, aplicado a $Y_i - \mathbb{E}[Y_i]$ e a $-(Y_i - \mathbb{E}[Y_i])$ com ε trocado por $n\varepsilon$: $\mathbb{P}(|\bar{Y} - \mathbb{E}[\bar{Y}]| \geq \varepsilon) \leq 2e^{-2n\varepsilon^2}$.

Borel-Cantelli Se $\sum_n \mathbb{P}(A_n) < \infty$, então $\mathbb{P}(A_n \text{ i.v.}) = 0$.
Uso: com $A_n = \{|T_n - \theta| > \varepsilon\}$ e a forma de cauda acima: se $\sum_n \mathbb{P}(|T_n - \theta| > \varepsilon) < \infty$ para todo $\varepsilon > 0$, então $T_n \xrightarrow{q.c.} \theta$. Toda cota do tipo $Ce^{-cn\varepsilon^2}$ é somável em n .

Método delta Se $\sqrt{n}(Y_n - \mu) \xrightarrow{d} N(0, \sigma^2)$ e g é derivável em μ :

$$\sqrt{n}(g(Y_n) - g(\mu)) \xrightarrow{d} N(0, g'(\mu)^2 \sigma^2).$$

Viés e variância $\text{MSE}(\hat{\theta}) = \mathbb{E}[(\hat{\theta} - \theta)^2] = (\mathbb{E}[\hat{\theta}] - \theta)^2 + \mathbb{V}(\hat{\theta})$.

Distribuição empírica

Definição $\hat{F}_n(y) = \frac{1}{n} \sum_{i=1}^n \mathbb{I}(X_i \leq y)$, para cada $y \in \mathbb{R}$.

Num ponto y fixo $n\hat{F}_n(y) \sim \text{Binomial}(n, F(y))$, logo

$$\mathbb{E}[\hat{F}_n(y)] = F(y), \quad \mathbb{V}[\hat{F}_n(y)] = \frac{F(y)(1 - F(y))}{n} \leq \frac{1}{4n}.$$

Erro máximo $D_n = \sup_{y \in \mathbb{R}} |\hat{F}_n(y) - F(y)|$.

Glivenko-Cantelli $D_n \xrightarrow{q.c.} 0$.

DKW $\mathbb{P}(D_n \geq \varepsilon) \leq 2e^{-2n\varepsilon^2}$, para todo $\varepsilon > 0$ e todo n .

Taxa q.c. Quase certamente, $D_n \leq 2\sqrt{\log n/n}$ para todo n suficientemente grande. Isto é, $D_n = O(\sqrt{\log n/n})$ q.c.

Taxa em probabilidade Por DKW, $\mathbb{P}(\sqrt{n}D_n \geq M) \leq 2e^{-2M^2}$ para todo n , logo $D_n = O_P(n^{-1/2})$: taxa melhor, modo mais fraco que a q.c.

Molde: consistência por Lipschitz

Se existe $L > 0$ tal que, para quaisquer FDs G_1, G_2 ,

$$|T(G_1) - T(G_2)| \leq L \sup_y |G_1(y) - G_2(y)|,$$

então $|T(\hat{F}_n) - T(F)| \leq L D_n$, logo $T(\hat{F}_n) \xrightarrow{q.c.} T(F)$, com $|T(\hat{F}_n) - T(F)| = O(\sqrt{\log n/n})$ q.c. e $|T(\hat{F}_n) - T(F)| = O_P(n^{-1/2})$.

Dimensão VC

$\mathcal{C}$ é uma classe de conjuntos e $A = \{x_1, \dots, x_k\}$ é um conjunto finito de pontos.

Fragmentar $\mathcal{C}$ fragmenta A se *todo* subconjunto de A é da forma $C \cap A$ para algum $C \in \mathcal{C}$.

Coeficiente $s(\mathcal{C}, n)$ = número máximo de subconjuntos distintos $C \cap A$, entre conjuntos A com n pontos. Sempre $s(\mathcal{C}, n) \leq 2^n$.

Dimensão VC $\text{VC}(\mathcal{C}) = \sup\{n : s(\mathcal{C}, n) = 2^n\}$, isto é, o maior n tal que *algum* conjunto de n pontos é fragmentado.

Sauer-Shelah Se $\text{VC}(\mathcal{C}) = d < \infty$, então $s(\mathcal{C}, n) \leq (n + 1)^d$.

Desigualdade de VC Com $P_n(C) = \frac{1}{n} \sum_i \mathbb{I}(X_i \in C)$:

$$\mathbb{P}\left(\sup_{C \in \mathcal{C}} |P_n(C) - P(C)| > \varepsilon\right) \leq 8 s(\mathcal{C}, n) e^{-n\varepsilon^2/32}.$$

Com Sauer-Shelah e Borel-Cantelli:
 $\text{VC}(\mathcal{C}) < \infty \Rightarrow \sup_{C \in \mathcal{C}} |P_n(C) - P(C)| \xrightarrow{q.c.} 0$, para toda P .

Classe $\mathcal{C}$	$\text{VC}(\mathcal{C})$
semirretas $(-\infty, a]$ em $\mathbb{R}$	1
intervalos $[a, b]$ em $\mathbb{R}$	2
retângulos $[a_1, b_1] \times [a_2, b_2]$	4
semiespaços em $\mathbb{R}^d$	$d + 1$

Receita para mostrar $\text{VC}(\mathcal{C}) = d$: (i) exiba *um* conjunto de d pontos e obtenha todos os seus subconjuntos; (ii) para *qualquer* conjunto de $d + 1$ pontos, ordene $x_1 < \dots < x_{d+1}$ e encontre um subconjunto que nenhum $C \in \mathcal{C}$ produz.

Funcionais e função de influência

Funcional $T : \{\text{FDs}\} \rightarrow \mathbb{R}$, $F \mapsto \theta = T(F)$, **um número**. O plug-in $T(\hat{F}_n)$ é aleatório porque $\hat{F}_n$ depende da amostra.

Funcional linear Existe uma função $g : \mathbb{R} \rightarrow \mathbb{R}$ tal que

$$T(F) = \int g(y) dF(y) = \mathbb{E}_F[g(X_1)].$$

O plug-in é a média amostral de g : $T(\hat{F}_n) = \frac{1}{n} \sum_{i=1}^n g(X_i)$.
Exemplos: média, $g(y) = y$; $F(t)$ com t fixo, $g(y) = \mathbb{I}(y \leq t)$.

Massa pontual em x_0 É a FD de uma v.a. Z que vale sempre x_0 :

$$\delta_{x_0}(y) = \mathbb{P}(Z \leq y) = \mathbb{I}(x_0 \leq y), \quad y \in \mathbb{R}.$$

Vale 0 para $y < x_0$ e 1 para $y \geq x_0$. É o $\hat{F}_n$ de uma única observação em x_0 .

Contaminação Para $\varepsilon \in [0, 1]$, a FD

$$F_\varepsilon(y) = (1 - \varepsilon)F(y) + \varepsilon \delta_{x_0}(y), \quad y \in \mathbb{R},$$

sorteia de F com prob. $1 - \varepsilon$ e devolve x_0 com prob. ε .

Função de influência Efeito em T de contaminar F no ponto x_0 :

$$\text{IF}(x_0) = \lim_{\varepsilon \rightarrow 0^+} \frac{T(F_\varepsilon) - T(F)}{\varepsilon} = \frac{d}{d\varepsilon} T(F_\varepsilon) \Big|_{\varepsilon=0}.$$

$\text{IF} : \mathbb{R} \rightarrow \mathbb{R}$ é uma **função**, construída a partir de T em F . Com $X \sim F$, $\text{IF}(X)$ é uma **v.a.** com $\mathbb{E}_F[\text{IF}(X)] = \int \text{IF}(y) dF(y) = 0$ (use para conferir a conta) e $\mathbb{V}_F[\text{IF}(X)] = \int \text{IF}(y)^2 dF(y) =: \tau^2$.

$T(F)$	$\text{IF}(x_0)$
$\int g(y) dF(y)$	$g(x_0) - T(F)$
média μ	$x_0 - \mu$
variância σ^2	$(x_0 - \mu)^2 - \sigma^2$

Regra da cadeia Se $T(F) = h(\theta_1, \dots, \theta_k)$ com $\theta_j = \int g_j(y) dF(y)$ e h diferenciável:

$$\text{IF}(x_0) = \sum_{j=1}^k \frac{\partial h}{\partial \theta_j}(\theta_1, \dots, \theta_k) (g_j(x_0) - \theta_j).$$

Expansão de von Mises Suposição:
 $T(G) - T(F) = \int \text{IF}(y) d(G - F)(y) + R(G, F)$ (o IF faz o papel do gradiente), com $\sqrt{n} R(\hat{F}_n, F) = o_P(1)$ e $\tau^2 \in (0, \infty)$.

Normalidade assintótica Sob essa suposição,

$$\sqrt{n}(T(\hat{F}_n) - T(F)) = \frac{1}{\sqrt{n}} \sum_{i=1}^n \text{IF}(X_i) + o_P(1) \xrightarrow{d} N(0, \tau^2).$$

Em particular, $T(\hat{F}_n) - T(F) = O_P(n^{-1/2})$ (convergência em distribuição implica $O_P(1)$).

Intervalo de confiança Se $\hat{\tau}^2 = \frac{1}{n} \sum_{i=1}^n \hat{\text{IF}}(X_i)^2$ é consistente para τ^2 ($\hat{\text{IF}}$: IF calculada em $\hat{F}_n$): $T(\hat{F}_n) \pm z_{1-\alpha/2} \hat{\tau}/\sqrt{n}$.

Jackknife e bootstrap

$\hat{\theta}_n = T(\hat{F}_n)$; $\hat{\theta}_{-i}$ é o mesmo estimador calculado *sem* X_i ;

$$\bar{\theta} = \frac{1}{n} \sum_{i=1}^n \hat{\theta}_{-i}.$$

Jackknife Viés: $\hat{b}_{\text{jack}} = (n-1)(\bar{\theta} - \hat{\theta}_n)$.

Estimador corrigido: $\hat{\theta}_{\text{jack}} = \hat{\theta}_n - \hat{b}_{\text{jack}} = n\hat{\theta}_n - (n-1)\bar{\theta}$.

Variância: $\hat{v}_{\text{jack}} = \frac{n-1}{n} \sum_{i=1}^n (\hat{\theta}_{-i} - \bar{\theta})^2$.

Por que funciona Se $\mathbb{E}[\hat{\theta}_n] = \theta + \frac{a}{n} + \frac{b}{n^2} + O(n^{-3})$, com a, b que não dependem de n , então $\mathbb{E}[\hat{b}_{\text{jack}}] = \frac{a}{n} + O(n^{-2})$ e $\mathbb{E}[\hat{\theta}_{\text{jack}}] - \theta = O(n^{-2})$, enquanto o viés de $\hat{\theta}_n$ é $\frac{a}{n} + O(n^{-2})$.

Identidade útil $\bar{X}_{-i} = \frac{n\bar{X} - X_i}{n-1}.$

Bootstrap Sorteie $X_1^*, \dots, X_n^*$ com reposição de $X_1, \dots, X_n$ (i.i.d. de $\hat{F}_n$) e calcule $\hat{\theta}^* = T(\hat{F}_n^*)$. Repita B vezes: $\hat{\theta}_1^*, \dots, \hat{\theta}_B^*$;

$$\bar{\theta}^* = \frac{1}{B} \sum_b \hat{\theta}_b^*.$$

Erro padrão $\hat{\text{se}}_{\text{boot}}^2 = \frac{1}{B-1} \sum_{b=1}^B (\hat{\theta}_b^* - \bar{\theta}^*)^2$.

Viés $\hat{b}^* = \mathbb{E}[\hat{\theta}^*] - \hat{\theta}_n$ ($\mathbb{E}^*$: esperança sob $\hat{F}_n$), aproximado por $\bar{\theta}^* - \hat{\theta}_n$.

Intervalos t: $\hat{\theta}_n \pm z_{1-\alpha/2} \hat{\text{se}}_{\text{boot}}$; percentil: $[q_{\alpha/2}^*, q_{1-\alpha/2}^*]$, quantis amostrais dos $\hat{\theta}_b^*$.

Estimação de densidade

Histograma (Aula 1)

Definição $[0, 1]$ dividido em m intervalos $B_1, \dots, B_m$ de comprimento $h = 1/m$:

$$\hat{f}_n(x) = \frac{1}{nh} \sum_{i=1}^n \mathbb{I}(X_i \in B_j), \quad x \in B_j.$$

(A1) $|f'(x)| \leq L$ em $[0, 1]$; logo $|f(u) - f(x)| \leq L|u - x|$.

Viés, cota e variância $|\mathbb{E}[\hat{f}_n(x)] - f(x)| \leq Lh$; $f(x) \leq 1 + L/2$; $\mathbb{V}[\hat{f}_n(x)] \leq \frac{f(x)+Lh}{nh}$.

Risco $\text{MSE}(\hat{f}_n(x)) \leq L^2 h^2 + \frac{1+L/2}{nh} + \frac{L}{n}$;

$\text{MISE}(\hat{f}_n) \leq L^2 h^2 + \frac{1}{nh} + \frac{L}{n}$.

Banda ótima (Lema 4) Os dois primeiros termos têm a forma

$$g_C(h) = \underbrace{L^2 h^2}_{\text{viés}^2} + \underbrace{\frac{C}{nh}}_{\text{variância}}, \quad h > 0,$$

uma cota do MSE como função da banda. $C > 0$ é a constante da cota da variância (não depende de n nem de h): $C = 1 + L/2$ no MSE pontual (usa $f \leq 1 + L/2$) e $C = 1$ no MISE (usa $\int_0^1 f = 1$). g_C é convexa e minimizada em

$$h_C = \left(\frac{C}{2L^2 n} \right)^{1/3}, \quad g_C(h_C) = 3 \cdot 2^{-2/3} (LC)^{2/3} n^{-2/3}.$$

Como $\frac{L}{n} = o(n^{-2/3})$: $\sup_x \text{MSE} = O(n^{-2/3})$ e $\text{MISE} = O(n^{-2/3})$, com $m \approx 1/h_C$, da ordem de $n^{1/3}$ intervalos.

h_C minimiza a *cota*, não o MSE, e depende de L desconhecido (na prática: validação cruzada).

Limite do método $\hat{f}_n$ é constante por partes: em geral o viés é da ordem de h mesmo se f é mais suave, e a taxa fica em $n^{-2/3}$. O KDE com kernel de ordem ℓ aproveita $\beta > 1$.

KDE (Aula 7)

Kernel $K: \mathbb{R} \rightarrow \mathbb{R}$ integrável com $\int K(u) du = 1$ e $\int K(u)^2 du < \infty$. Notação: $\kappa_j = \int |u|^j |K(u)| du$.

Ordem k $\kappa_k < \infty$ e $\int u^j K(u) du = 0$ para $j = 1, \dots, k$. Simétrico com $\kappa_1 < \infty \Rightarrow$ ordem 1.

KDE Com banda $h > 0$:

$$\hat{f}_n(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{X_i - x}{h}\right).$$

Esperança e variância Trocando $u = (y - x)/h$:

$$\mathbb{E}[\hat{f}_n(x)] = \int K(u) f(x + uh) du,$$

$$\mathbb{V}[\hat{f}_n(x)] \leq \frac{1}{nh} \int K(u)^2 f(x + uh) du \leq \frac{\sup_y f(y) \int K(u)^2 du}{nh}.$$

Classe de Hölder Sejam $\beta > 0$, $L > 0$ e ℓ o maior inteiro *estritamente* menor que β . $\Sigma(\beta, L)$ é o conjunto das funções $f: \mathbb{R} \rightarrow \mathbb{R}$ que são ℓ vezes deriváveis e tais que

$$|f^{(\ell)}(y) - f^{(\ell)}(x)| \leq L|y - x|^{\beta-\ell}, \quad \text{para todos } x, y \in \mathbb{R}.$$

Para $\beta \leq 1$: $\ell = 0$ e a condição é $|f(y) - f(x)| \leq L|y - x|^\beta$. Em particular, $\Sigma(1, L)$ é a classe das funções L -Lipschitz (não exige derivada), que contém as f com $|f'| \leq L$ da (A1) do histograma. Usada para densidades f e para funções de regressão r .

Hipótese $f \in \Sigma(\beta, L)$ e K limitado, de ordem ℓ , com $\kappa_\beta < \infty$. (C depende só de β, L, K .)

Viés $|\mathbb{E}[\hat{f}_n(x)] - f(x)| \leq C h^\beta$ (com $C = L\kappa_\beta/\ell!$).

Variância f é limitada, logo $\mathbb{V}[\hat{f}_n(x)] \leq \frac{C}{nh}$.

Risco $\text{MSE}(\hat{f}_n(x)) \leq C(h^{2\beta} + \frac{1}{nh})$ para todos x, h . Com $h = n^{-1/(2\beta+1)}$ os dois termos são iguais e

$$\sup_x \text{MSE}(\hat{f}_n(x)) \leq 2C n^{-\frac{2\beta}{2\beta+1}} = O(n^{-\frac{2\beta}{2\beta+1}}).$$

Por quê (mesma conta do Lema 4, não está nas notas): $Ah^{2\beta} + \frac{B}{nh}$, com $A, B > 0$, tem único ponto crítico em $h > 0$, que é o mínimo:

$$h^* = \left(\frac{B}{2\beta A n} \right)^{\frac{1}{2\beta+1}}, \quad \text{valor} = O(n^{-\frac{2\beta}{2\beta+1}}).$$

Para $\beta = 1$ volta a taxa $n^{-2/3}$ do histograma.

Em probabilidade Markov com $r = 2$ ($\nu_{n2} = \text{MSE}$):

$$\mathbb{P}(|\hat{f}_n(x) - f(x)| > M n^{-\frac{\beta}{2\beta+1}}) \leq \frac{2C}{M^2}, \text{ logo}$$

$$|\hat{f}_n(x) - f(x)| = O_P(n^{-\frac{\beta}{2\beta+1}}) \text{ e } \hat{f}_n(x) \xrightarrow{P} f(x).$$

Validação cruzada $\hat{f}_{-i}(x) = \frac{1}{(n-1)h} \sum_{j \neq i} K\left(\frac{X_j - x}{h}\right)$ (sem X_i):

$$\text{CV}(h) = \int \hat{f}_n(x)^2 dx - \frac{2}{n} \sum_{i=1}^n \hat{f}_{-i}(X_i),$$

$$\mathbb{E}[\text{CV}(h)] = \mathbb{E} \int (\hat{f}_n(x) - f(x))^2 dx - \int f(x)^2 dx.$$

Roteiro para viés/variância/MSE

- Escrever a esperança como integral em y .
- Trocar $u = (y - x)/h$, $dy = h du$.
- Usar $\int K(u) du = 1$ para escrever $\mathbb{E}[\hat{f}_n(x)] - f(x) = \int K(u) (f(x + uh) - f(x)) du$.
- Cotar $|f(x + uh) - f(x)|$ pela suavidade.
- Variância: $\mathbb{V}(Z) \leq \mathbb{E}[Z^2]$.
- Escolher h que iguala viés² e variância (ver Risco e Lema 4).

Regressão: linear smoothers

Modelo: $Y_i = r(X_i) + \varepsilon_i$, $\mathbb{E}[\varepsilon_i | X_i] = 0$, $\mathbb{V}[\varepsilon_i | X_i] = \sigma^2$; dado $\mathbf{X} = (X_1, \dots, X_n)$, os ε_i são independentes.

Linear smoother $\hat{r}_n(x) = \sum_{i=1}^n \ell_i(x) Y_i$, com pesos $\ell_i(x)$ que dependem de x e dos X_i , mas não dos Y_i .

Nadaraya-Watson $\ell_i(x) = \frac{K((X_i - x)/h)}{\sum_{s=1}^n K((X_s - x)/h)}.$

Viés e variância (dado X) Se $\sum_i \ell_i(x) = 1$:

$$\mathbb{E}[\hat{r}_n(x) | \mathbf{X}] - r(x) = \sum_{i=1}^n \ell_i(x) (r(X_i) - r(x)),$$

$$\mathbb{V}[\hat{r}_n(x) | \mathbf{X}] = \sigma^2 \sum_{i=1}^n \ell_i(x)^2.$$

Risco ($\beta \leq 1$) Se $r \in \Sigma(\beta, L)$ e, para x e h fixos: $\sum_i \ell_i(x) = 1$; $\ell_i(x) = 0$ quando $|X_i - x| > h$; $\sum_i |\ell_i(x)| \leq C_0$; $\max_i |\ell_i(x)| \leq \frac{C_0}{nh}$. Então

$$|\text{viés}| \leq LC_0 h^\beta, \quad \mathbb{V}[\hat{r}_n(x) | \mathbf{X}] \leq \frac{\sigma^2 C_0^2}{nh}.$$

Mesma cota e mesma escolha de h do KDE. (Para $\beta > 1$, exigir também $\sum_i \ell_i(x)(X_i - x)^j = 0$, $j = 1, \dots, \ell$.)

Validação cruzada Se $\ell_j(x) = g_j(x) / \sum_s g_s(x)$, com $g_j(x) \geq 0$ dependendo só de x e X_j (ex.: Nadaraya-Watson), ou para mínimos quadrados; com $L_{ii} = \ell_i(X_i)$:

$$\text{CV} = \frac{1}{n} \sum_{i=1}^n \left(\frac{Y_i - \hat{r}_n(X_i)}{1 - L_{ii}} \right)^2.$$