

## Formulário resumido – Estatística Não-Paramétrica

**Convenções.**  $X_1, \dots, X_n$  i.i.d. com função de distribuição (FD)  $F$ . Toda função aparece com o seu argumento:  $F(y)$ ,  $g(y)$ ,  $K(u)$ , etc. A letra  $y$  é sempre a variável de integração ou o argumento de uma FD;  $x_0$  é um ponto fixo.

### Ordens

$b_n > 0$  é uma sequência determinística.

**Números** Para viés, variância, MSE,  $\mathbb{E}[\cdot]$ ,  $\mathbb{P}(\cdot)$ , com  $a_n \geq 0$ :  $a_n = O(b_n)$  se existe  $C > 0$ , que não depende de  $n$ , com  $a_n \leq C b_n$  para  $n$  grande;  $a_n = o(b_n)$  se  $a_n/b_n \rightarrow 0$ . O mesmo vale com  $h \rightarrow 0$  no lugar de  $n \rightarrow \infty$ , e com  $C$  que não depende de  $x$  (cota uniforme).

**V.a., trajetória a trajetória**  $Z_n = O(b_n)$  q.c. se, para quase todo  $\omega$ , a sequência de números  $|Z_n(\omega)|$  é  $O(b_n)$ .

**V.a., em probabilidade**  $Z_n = O_P(b_n)$  se, para todo  $\eta > 0$ , existem  $M, N$  com  $\mathbb{P}(|Z_n| > M b_n) < \eta$  para todo  $n \geq N$ ;  $Z_n = o_P(b_n)$  se  $Z_n/b_n \xrightarrow{P} 0$ .

**Relações**  $Z_n = O(b_n)$  q.c.  $\Rightarrow Z_n = O_P(b_n)$ . Se  $b_n \rightarrow 0$ :  $Z_n = O(b_n)$  q.c.  $\Rightarrow Z_n \xrightarrow{q.c.} 0$ ;  $Z_n = O_P(b_n) \Rightarrow Z_n \xrightarrow{P} 0$ , mas em geral *não* implica  $Z_n \xrightarrow{q.c.} 0$ .

### Convergência

**Em probabilidade**  $X_n \xrightarrow{P} X$  se, para todo  $\varepsilon > 0$ ,  $\mathbb{P}(|X_n - X| > \varepsilon) \rightarrow 0$  quando  $n \rightarrow \infty$ .

**Quase certa**  $X_n \xrightarrow{q.c.} X$  se  $\mathbb{P}(\lim_{n \rightarrow \infty} |X_n - X| = 0) = 1$ .

**Quase certa (eventos de cauda)** Equivalentemente, para todo  $\varepsilon > 0$ ,

$$\mathbb{P}(|X_n - X| > \varepsilon \text{ infinitas vezes}) = 0,$$

em que  $\{A_n \text{ i.v.}\} = \limsup_n A_n = \bigcap_{m \geq 1} \bigcup_{n \geq m} A_n$ . Também equivale a  $\mathbb{P}(\sup_{n \geq m} |X_n - X| > \varepsilon) \rightarrow 0$  quando  $m \rightarrow \infty$ .

**Em distribuição**  $X_n \xrightarrow{d} X$  se  $\mathbb{P}(X_n \leq t) \rightarrow \mathbb{P}(X \leq t)$  em todo ponto  $t$  de continuidade de  $t \mapsto \mathbb{P}(X \leq t)$ .

**Relações**  $X_n \xrightarrow{q.c.} X \Rightarrow X_n \xrightarrow{P} X \Rightarrow X_n \xrightarrow{d} X$ ; e  $X_n \xrightarrow{d} c$  (constante)  $\Rightarrow X_n \xrightarrow{P} c$ .

### Ferramentas

**Markov** Denotando  $\nu_{nr} = \mathbb{E}|T_n - \theta|^r < \infty$ , para algum  $r > 0$ , vale, para  $t > 0$ ,

$$\mathbb{P}(|T_n - \theta| > t) \leq \frac{\nu_{nr}}{t^r}.$$

**Chebyshev** Caso  $r = 2$  com  $\mathbb{E}[T_n] = \theta$ :  $\mathbb{P}(|T_n - \theta| > t) \leq \frac{\mathbb{V}(T_n)}{t^2}$ .

**Hoeffding**  $Y_1, \dots, Y_n$  independentes,  $\mathbb{E}[Y_i] = 0$  e  $a_i \leq Y_i \leq b_i$ . Para  $\varepsilon > 0$  e qualquer  $t > 0$ ,

$$\mathbb{P}\left(\sum_{i=1}^n Y_i \geq \varepsilon\right) \leq e^{-t\varepsilon} \prod_{i=1}^n e^{t^2(b_i - a_i)^2/8}.$$

Escolhendo  $t = 4\varepsilon / \sum_i (b_i - a_i)^2$ :  $\leq \exp(-2\varepsilon^2 / \sum_i (b_i - a_i)^2)$ .  
Caso das aulas:  $Y_i \in [0, 1]$ , aplicado a  $Y_i - \mathbb{E}[Y_i]$  e a  $-(Y_i - \mathbb{E}[Y_i])$  com  $\varepsilon$  trocado por  $n\varepsilon$ :  $\mathbb{P}(|\bar{Y} - \mathbb{E}[\bar{Y}]| \geq \varepsilon) \leq 2e^{-2n\varepsilon^2}$ .

**Borel-Cantelli** Se  $\sum_n \mathbb{P}(A_n) < \infty$ , então  $\mathbb{P}(A_n \text{ i.v.}) = 0$ .  
*Uso:* com  $A_n = \{|T_n - \theta| > \varepsilon\}$  e a forma de cauda acima: se  $\sum_n \mathbb{P}(|T_n - \theta| > \varepsilon) < \infty$  para todo  $\varepsilon > 0$ , então  $T_n \xrightarrow{q.c.} \theta$ . Toda cota do tipo  $Ce^{-cn\varepsilon^2}$  é somável em  $n$ .

**Método delta** Se  $\sqrt{n}(Y_n - \mu) \xrightarrow{d} N(0, \sigma^2)$  e  $g$  é derivável em  $\mu$ :

$$\sqrt{n}(g(Y_n) - g(\mu)) \xrightarrow{d} N(0, g'(\mu)^2 \sigma^2).$$

**Viés e variância**  $\text{MSE}(\hat{\theta}) = \mathbb{E}[(\hat{\theta} - \theta)^2] = (\mathbb{E}[\hat{\theta}] - \theta)^2 + \mathbb{V}(\hat{\theta})$ .

### Distribuição empírica

**Definição**  $\hat{F}_n(y) = \frac{1}{n} \sum_{i=1}^n \mathbb{I}(X_i \leq y)$ , para cada  $y \in \mathbb{R}$ .

**Num ponto y fixo**  $n\hat{F}_n(y) \sim \text{Binomial}(n, F(y))$ , logo

$$\mathbb{E}[\hat{F}_n(y)] = F(y), \quad \mathbb{V}[\hat{F}_n(y)] = \frac{F(y)(1 - F(y))}{n} \leq \frac{1}{4n}.$$

**Erro máximo**  $D_n = \sup_{y \in \mathbb{R}} |\hat{F}_n(y) - F(y)|$ .

**Glivenko-Cantelli**  $D_n \xrightarrow{q.c.} 0$ .

**DKW**  $\mathbb{P}(D_n \geq \varepsilon) \leq 2e^{-2n\varepsilon^2}$ , para todo  $\varepsilon > 0$  e todo  $n$ .

**Taxa q.c.** Quase certamente,  $D_n \leq 2\sqrt{\log n/n}$  para todo  $n$  suficientemente grande. Isto é,  $D_n = O(\sqrt{\log n/n})$  q.c.

**Taxa em probabilidade** Por DKW,  $\mathbb{P}(\sqrt{n}D_n \geq M) \leq 2e^{-2M^2}$  para todo  $n$ , logo  $D_n = O_P(n^{-1/2})$ : taxa melhor, modo mais fraco que a q.c.

**Molde: consistência por Lipschitz**

Se existe  $L > 0$  tal que, para quaisquer FDs  $G_1, G_2$ ,

$$|T(G_1) - T(G_2)| \leq L \sup_y |G_1(y) - G_2(y)|,$$

então  $|T(\hat{F}_n) - T(F)| \leq L D_n$ , logo  $T(\hat{F}_n) \xrightarrow{q.c.} T(F)$ , com  $|T(\hat{F}_n) - T(F)| = O(\sqrt{\log n/n})$  q.c. e  $|T(\hat{F}_n) - T(F)| = O_P(n^{-1/2})$ .

### Dimensão VC

$\mathcal{C}$  é uma classe de conjuntos e  $A = \{x_1, \dots, x_k\}$  é um conjunto finito de pontos.

**Fragmentar**  $\mathcal{C}$  fragmenta  $A$  se *todo* subconjunto de  $A$  é da forma  $C \cap A$  para algum  $C \in \mathcal{C}$ .

**Coeficiente**  $s(\mathcal{C}, n)$  = número máximo de subconjuntos distintos  $C \cap A$ , entre conjuntos  $A$  com  $n$  pontos. Sempre  $s(\mathcal{C}, n) \leq 2^n$ .

**Dimensão VC**  $\text{VC}(\mathcal{C}) = \sup\{n : s(\mathcal{C}, n) = 2^n\}$ , isto é, o maior  $n$  tal que *algum* conjunto de  $n$  pontos é fragmentado.

**Sauer-Shelah** Se  $\text{VC}(\mathcal{C}) = d < \infty$ , então  $s(\mathcal{C}, n) \leq (n + 1)^d$ .

**Desigualdade de VC** Com  $P_n(C) = \frac{1}{n} \sum_i \mathbb{I}(X_i \in C)$ :

$$\mathbb{P}\left(\sup_{C \in \mathcal{C}} |P_n(C) - P(C)| > \varepsilon\right) \leq 8 s(\mathcal{C}, n) e^{-n\varepsilon^2/32}.$$

Com Sauer-Shelah e Borel-Cantelli:  
 $\text{VC}(\mathcal{C}) < \infty \Rightarrow \sup_{C \in \mathcal{C}} |P_n(C) - P(C)| \xrightarrow{q.c.} 0$ , para toda  $P$ .

| Classe $\mathcal{C}$                      | $\text{VC}(\mathcal{C})$ |
|-------------------------------------------|--------------------------|
| semirretas $(-\infty, a]$ em $\mathbb{R}$ | 1                        |
| intervalos $[a, b]$ em $\mathbb{R}$       | 2                        |
| retângulos $[a_1, b_1] \times [a_2, b_2]$ | 4                        |
| semiespaços em $\mathbb{R}^d$             | $d + 1$                  |

**Receita para mostrar  $\text{VC}(\mathcal{C}) = d$ :** (i) exiba *um* conjunto de  $d$  pontos e obtenha todos os seus subconjuntos; (ii) para *qualquer* conjunto de  $d + 1$  pontos, ordene  $x_1 < \dots < x_{d+1}$  e encontre um subconjunto que nenhum  $C \in \mathcal{C}$  produz.

### Funcionais e função de influência

**Funcional**  $T : \{\text{FDs}\} \rightarrow \mathbb{R}$ ,  $F \mapsto \theta = T(F)$ , **um número**. O plug-in  $T(\hat{F}_n)$  é aleatório porque  $\hat{F}_n$  depende da amostra.

**Funcional linear** Existe uma função  $g : \mathbb{R} \rightarrow \mathbb{R}$  tal que

$$T(F) = \int g(y) dF(y) = \mathbb{E}_F[g(X_1)].$$

O plug-in é a média amostral de  $g$ :  $T(\hat{F}_n) = \frac{1}{n} \sum_{i=1}^n g(X_i)$ .  
*Exemplos:* média,  $g(y) = y$ ;  $F(t)$  com  $t$  fixo,  $g(y) = \mathbb{I}(y \leq t)$ .

**Massa pontual em  $x_0$**  É a FD de uma v.a.  $Z$  que vale sempre  $x_0$ :

$$\delta_{x_0}(y) = \mathbb{P}(Z \leq y) = \mathbb{I}(x_0 \leq y), \quad y \in \mathbb{R}.$$

Vale 0 para  $y < x_0$  e 1 para  $y \geq x_0$ . É o  $\hat{F}_n$  de uma única observação em  $x_0$ .

**Contaminação** Para  $\varepsilon \in [0, 1]$ , a FD

$$F_\varepsilon(y) = (1 - \varepsilon)F(y) + \varepsilon \delta_{x_0}(y), \quad y \in \mathbb{R},$$

sorteia de  $F$  com prob.  $1 - \varepsilon$  e devolve  $x_0$  com prob.  $\varepsilon$ .

**Função de influência** Efeito em  $T$  de contaminar  $F$  no ponto  $x_0$ :

$$\text{IF}(x_0) = \lim_{\varepsilon \rightarrow 0^+} \frac{T(F_\varepsilon) - T(F)}{\varepsilon} = \frac{d}{d\varepsilon} T(F_\varepsilon) \Big|_{\varepsilon=0}.$$

$\text{IF} : \mathbb{R} \rightarrow \mathbb{R}$  é uma **função**, construída a partir de  $T$  em  $F$ . Com  $X \sim F$ ,  $\text{IF}(X)$  é uma **v.a.** com  $\mathbb{E}_F[\text{IF}(X)] = \int \text{IF}(y) dF(y) = 0$  (use para conferir a conta) e  $\mathbb{V}_F[\text{IF}(X)] = \int \text{IF}(y)^2 dF(y) =: \tau^2$ .

| $T(F)$               | $\text{IF}(x_0)$           |
|----------------------|----------------------------|
| $\int g(y) dF(y)$    | $g(x_0) - T(F)$            |
| média $\mu$          | $x_0 - \mu$                |
| variância $\sigma^2$ | $(x_0 - \mu)^2 - \sigma^2$ |

**Regra da cadeia** Se  $T(F) = h(\theta_1, \dots, \theta_k)$  com  $\theta_j = \int g_j(y) dF(y)$  e  $h$  diferenciável:

$$\text{IF}(x_0) = \sum_{j=1}^k \frac{\partial h}{\partial \theta_j}(\theta_1, \dots, \theta_k) (g_j(x_0) - \theta_j).$$

**Expansão de von Mises** Suposição:  
 $T(G) - T(F) = \int \text{IF}(y) d(G - F)(y) + R(G, F)$  (o IF faz o papel do gradiente), com  $\sqrt{n} R(\hat{F}_n, F) = o_P(1)$  e  $\tau^2 \in (0, \infty)$ .

**Normalidade assintótica** Sob essa suposição,

$$\sqrt{n}(T(\hat{F}_n) - T(F)) = \frac{1}{\sqrt{n}} \sum_{i=1}^n \text{IF}(X_i) + o_P(1) \xrightarrow{d} N(0, \tau^2).$$

Em particular,  $T(\hat{F}_n) - T(F) = O_P(n^{-1/2})$  (convergência em distribuição implica  $O_P(1)$ ).

**Intervalo de confiança** Se  $\hat{\tau}^2 = \frac{1}{n} \sum_{i=1}^n \hat{\text{IF}}(X_i)^2$  é consistente para  $\tau^2$  ( $\hat{\text{IF}}$ : IF calculada em  $\hat{F}_n$ ):  $T(\hat{F}_n) \pm z_{1-\alpha/2} \hat{\tau}/\sqrt{n}$ .

### Jackknife e bootstrap

$\hat{\theta}_n = T(\hat{F}_n)$ ;  $\hat{\theta}_{-i}$  é o mesmo estimador calculado *sem*  $X_i$ ;

$$\bar{\theta} = \frac{1}{n} \sum_{i=1}^n \hat{\theta}_{-i}.$$

**Jackknife** Viés:  $\hat{b}_{\text{jack}} = (n-1)(\bar{\theta} - \hat{\theta}_n)$ .

Estimador corrigido:  $\hat{\theta}_{\text{jack}} = \hat{\theta}_n - \hat{b}_{\text{jack}} = n\hat{\theta}_n - (n-1)\bar{\theta}$ .

Variância:  $\hat{v}_{\text{jack}} = \frac{n-1}{n} \sum_{i=1}^n (\hat{\theta}_{-i} - \bar{\theta})^2$ .

**Por que funciona** Se  $\mathbb{E}[\hat{\theta}_n] = \theta + \frac{a}{n} + \frac{b}{n^2} + O(n^{-3})$ , com  $a, b$  que não dependem de  $n$ , então  $\mathbb{E}[\hat{b}_{\text{jack}}] = \frac{a}{n} + O(n^{-2})$  e  $\mathbb{E}[\hat{\theta}_{\text{jack}}] - \theta = O(n^{-2})$ , enquanto o viés de  $\hat{\theta}_n$  é  $\frac{a}{n} + O(n^{-2})$ .

**Identidade útil**  $\bar{X}_{-i} = \frac{n\bar{X} - X_i}{n-1}.$

**Bootstrap** Sorteie  $X_1^*, \dots, X_n^*$  com reposição de  $X_1, \dots, X_n$  (i.i.d. de  $\hat{F}_n$ ) e calcule  $\hat{\theta}^* = T(\hat{F}_n^*)$ . Repita  $B$  vezes:  $\hat{\theta}_1^*, \dots, \hat{\theta}_B^*$ ;

$$\bar{\theta}^* = \frac{1}{B} \sum_b \hat{\theta}_b^*.$$

**Erro padrão**  $\hat{\text{se}}_{\text{boot}}^2 = \frac{1}{B-1} \sum_{b=1}^B (\hat{\theta}_b^* - \bar{\theta}^*)^2$ .

**Viés**  $\hat{b}^* = \mathbb{E}[\hat{\theta}^*] - \hat{\theta}_n$  ( $\mathbb{E}^*$ : esperança sob  $\hat{F}_n$ ), aproximado por  $\bar{\theta}^* - \hat{\theta}_n$ .

**Intervalos** t:  $\hat{\theta}_n \pm z_{1-\alpha/2} \hat{\text{se}}_{\text{boot}}$ ; percentil:  $[q_{\alpha/2}^*, q_{1-\alpha/2}^*]$ , quantis amostrais dos  $\hat{\theta}_b^*$ .

### Estimação de densidade

#### Histograma (Aula 1)

**Definição**  $[0, 1]$  dividido em  $m$  intervalos  $B_1, \dots, B_m$  de comprimento  $h = 1/m$ :

$$\hat{f}_n(x) = \frac{1}{nh} \sum_{i=1}^n \mathbb{I}(X_i \in B_j), \quad x \in B_j.$$

(A1)  $|f'(x)| \leq L$  em  $[0, 1]$ ; logo  $|f(u) - f(x)| \leq L|u - x|$ .

**Viés, cota e variância**  $|\mathbb{E}[\hat{f}_n(x)] - f(x)| \leq Lh$ ;  $f(x) \leq 1 + L/2$ ;  $\mathbb{V}[\hat{f}_n(x)] \leq \frac{f(x)+Lh}{nh}$ .

**Risco**  $\text{MSE}(\hat{f}_n(x)) \leq L^2 h^2 + \frac{1+L/2}{nh} + \frac{L}{n}$ ;

$\text{MISE}(\hat{f}_n) \leq L^2 h^2 + \frac{1}{nh} + \frac{L}{n}$ .

**Banda ótima (Lema 4)** Os dois primeiros termos têm a forma

$$g_C(h) = \underbrace{L^2 h^2}_{\text{viés}^2} + \underbrace{\frac{C}{nh}}_{\text{variância}}, \quad h > 0,$$

uma cota do MSE como função da banda.  $C > 0$  é a constante da cota da variância (não depende de  $n$  nem de  $h$ ):  $C = 1 + L/2$  no MSE pontual (usa  $f \leq 1 + L/2$ ) e  $C = 1$  no MISE (usa  $\int_0^1 f = 1$ ).  $g_C$  é convexa e minimizada em

$$h_C = \left( \frac{C}{2L^2 n} \right)^{1/3}, \quad g_C(h_C) = 3 \cdot 2^{-2/3} (LC)^{2/3} n^{-2/3}.$$

Como  $\frac{L}{n} = o(n^{-2/3})$ :  $\sup_x \text{MSE} = O(n^{-2/3})$  e  $\text{MISE} = O(n^{-2/3})$ , com  $m \approx 1/h_C$ , da ordem de  $n^{1/3}$  intervalos.

$h_C$  minimiza a *cota*, não o MSE, e depende de  $L$  desconhecido (na prática: validação cruzada).

**Limite do método**  $\hat{f}_n$  é constante por partes: em geral o viés é da ordem de  $h$  mesmo se  $f$  é mais suave, e a taxa fica em  $n^{-2/3}$ . O KDE com kernel de ordem  $\ell$  aproveita  $\beta > 1$ .

#### KDE (Aula 7)

**Kernel**  $K: \mathbb{R} \rightarrow \mathbb{R}$  integrável com  $\int K(u) du = 1$  e  $\int K(u)^2 du < \infty$ . Notação:  $\kappa_j = \int |u|^j |K(u)| du$ .

**Ordem**  $k$   $\kappa_k < \infty$  e  $\int u^j K(u) du = 0$  para  $j = 1, \dots, k$ . Simétrico com  $\kappa_1 < \infty \Rightarrow$  ordem 1.

**KDE** Com banda  $h > 0$ :

$$\hat{f}_n(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{X_i - x}{h}\right).$$

**Esperança e variância** Trocando  $u = (y - x)/h$ :

$$\mathbb{E}[\hat{f}_n(x)] = \int K(u) f(x + uh) du,$$

$$\mathbb{V}[\hat{f}_n(x)] \leq \frac{1}{nh} \int K(u)^2 f(x + uh) du \leq \frac{\sup_y f(y) \int K(u)^2 du}{nh}.$$

**Classe de Hölder** Sejam  $\beta > 0$ ,  $L > 0$  e  $\ell$  o maior inteiro *estritamente* menor que  $\beta$ .  $\Sigma(\beta, L)$  é o conjunto das funções  $f: \mathbb{R} \rightarrow \mathbb{R}$  que são  $\ell$  vezes deriváveis e tais que

$$|f^{(\ell)}(y) - f^{(\ell)}(x)| \leq L|y - x|^{\beta-\ell}, \quad \text{para todos } x, y \in \mathbb{R}.$$

Para  $\beta \leq 1$ :  $\ell = 0$  e a condição é  $|f(y) - f(x)| \leq L|y - x|^\beta$ . Em particular,  $\Sigma(1, L)$  é a classe das funções  $L$ -Lipschitz (não exige derivada), que contém as  $f$  com  $|f'| \leq L$  da (A1) do histograma. Usada para densidades  $f$  e para funções de regressão  $r$ .

**Hipótese**  $f \in \Sigma(\beta, L)$  e  $K$  limitado, de ordem  $\ell$ , com  $\kappa_\beta < \infty$ . ( $C$  depende só de  $\beta, L, K$ .)

**Viés**  $|\mathbb{E}[\hat{f}_n(x)] - f(x)| \leq C h^\beta$  (com  $C = L\kappa_\beta/\ell!$ ).

**Variância**  $f$  é limitada, logo  $\mathbb{V}[\hat{f}_n(x)] \leq \frac{C}{nh}$ .

**Risco**  $\text{MSE}(\hat{f}_n(x)) \leq C(h^{2\beta} + \frac{1}{nh})$  para todos  $x, h$ . Com  $h = n^{-1/(2\beta+1)}$  os dois termos são iguais e

$$\sup_x \text{MSE}(\hat{f}_n(x)) \leq 2C n^{-\frac{2\beta}{2\beta+1}} = O(n^{-\frac{2\beta}{2\beta+1}}).$$

*Por quê* (mesma conta do Lema 4, não está nas notas):  $Ah^{2\beta} + \frac{B}{nh}$ , com  $A, B > 0$ , tem único ponto crítico em  $h > 0$ , que é o mínimo:

$$h^* = \left( \frac{B}{2\beta A n} \right)^{\frac{1}{2\beta+1}}, \quad \text{valor} = O(n^{-\frac{2\beta}{2\beta+1}}).$$

Para  $\beta = 1$  volta a taxa  $n^{-2/3}$  do histograma.

**Em probabilidade** Markov com  $r = 2$  ( $\nu_{n2} = \text{MSE}$ ):

$$\mathbb{P}(|\hat{f}_n(x) - f(x)| > M n^{-\frac{\beta}{2\beta+1}}) \leq \frac{2C}{M^2}, \text{ logo}$$

$$|\hat{f}_n(x) - f(x)| = O_P(n^{-\frac{\beta}{2\beta+1}}) \text{ e } \hat{f}_n(x) \xrightarrow{P} f(x).$$

**Validação cruzada**  $\hat{f}_{-i}(x) = \frac{1}{(n-1)h} \sum_{j \neq i} K\left(\frac{X_j - x}{h}\right)$  (sem  $X_i$ ):

$$\text{CV}(h) = \int \hat{f}_n(x)^2 dx - \frac{2}{n} \sum_{i=1}^n \hat{f}_{-i}(X_i),$$

$$\mathbb{E}[\text{CV}(h)] = \mathbb{E} \int (\hat{f}_n(x) - f(x))^2 dx - \int f(x)^2 dx.$$

#### Roteiro para viés/variância/MSE

- Escrever a esperança como integral em  $y$ .
- Trocar  $u = (y - x)/h$ ,  $dy = h du$ .
- Usar  $\int K(u) du = 1$  para escrever  $\mathbb{E}[\hat{f}_n(x)] - f(x) = \int K(u) (f(x + uh) - f(x)) du$ .
- Cotar  $|f(x + uh) - f(x)|$  pela suavidade.
- Variância:  $\mathbb{V}(Z) \leq \mathbb{E}[Z^2]$ .
- Escolher  $h$  que iguala viés<sup>2</sup> e variância (ver Risco e Lema 4).

#### Regressão: linear smoothers

Modelo:  $Y_i = r(X_i) + \varepsilon_i$ ,  $\mathbb{E}[\varepsilon_i | X_i] = 0$ ,  $\mathbb{V}[\varepsilon_i | X_i] = \sigma^2$ ; dado  $\mathbf{X} = (X_1, \dots, X_n)$ , os  $\varepsilon_i$  são independentes.

**Linear smoother**  $\hat{r}_n(x) = \sum_{i=1}^n \ell_i(x) Y_i$ , com pesos  $\ell_i(x)$  que dependem de  $x$  e dos  $X_i$ , mas não dos  $Y_i$ .

**Nadaraya-Watson**  $\ell_i(x) = \frac{K((X_i - x)/h)}{\sum_{s=1}^n K((X_s - x)/h)}.$

**Viés e variância (dado X)** Se  $\sum_i \ell_i(x) = 1$ :

$$\mathbb{E}[\hat{r}_n(x) | \mathbf{X}] - r(x) = \sum_{i=1}^n \ell_i(x) (r(X_i) - r(x)),$$

$$\mathbb{V}[\hat{r}_n(x) | \mathbf{X}] = \sigma^2 \sum_{i=1}^n \ell_i(x)^2.$$

**Risco** ( $\beta \leq 1$ ) Se  $r \in \Sigma(\beta, L)$  e, para  $x$  e  $h$  fixos:  $\sum_i \ell_i(x) = 1$ ;  $\ell_i(x) = 0$  quando  $|X_i - x| > h$ ;  $\sum_i |\ell_i(x)| \leq C_0$ ;  $\max_i |\ell_i(x)| \leq \frac{C_0}{nh}$ . Então

$$|\text{viés}| \leq LC_0 h^\beta, \quad \mathbb{V}[\hat{r}_n(x) | \mathbf{X}] \leq \frac{\sigma^2 C_0^2}{nh}.$$

Mesma cota e mesma escolha de  $h$  do KDE. (Para  $\beta > 1$ , exigir também  $\sum_i \ell_i(x)(X_i - x)^j = 0$ ,  $j = 1, \dots, \ell$ .)

**Validação cruzada** Se  $\ell_j(x) = g_j(x) / \sum_s g_s(x)$ , com  $g_j(x) \geq 0$  dependendo só de  $x$  e  $X_j$  (ex.: Nadaraya-Watson), ou para mínimos quadrados; com  $L_{ii} = \ell_i(X_i)$ :

$$\text{CV} = \frac{1}{n} \sum_{i=1}^n \left( \frac{Y_i - \hat{r}_n(X_i)}{1 - L_{ii}} \right)^2.$$